Classificador de fusão de características com memória de longo e curto prazo de fluxo duplo para reconhecimento de gestos por eletromiografia de superfície

Kexin Zhang[1], Francisco J. Badesa[1], Yinlong Liu[2] e Manuel Ferre Pérez[1,*]

[1] Centro de Automação e Robótica (CAR) UPM-CSIC, Universidade Politécnica de Madri (UPM), 28006 Madri, Espanha; kexin.zhang@alumnos.upm.es (K.Z.); javier.badesa@upm.es (F.J.B.)
[2] Laboratório Estatal de Referência de Internet das Coisas para Cidades Inteligentes, Universidade de Macau, Macau; yinlongliu@um.edu.mo
* Correspondência: m.ferre@upm.es

Resumo

O reconhecimento de gestos por meio de sinais de eletromiografia (EMG) ganhou destaque recentemente na área de interação humano-computador para o controle de próteses inteligentes. Atualmente, aprendizado de máquina e aprendizado profundo são os dois métodos mais empregados na classificação de gestos da mão. Embora os métodos tradicionais de aprendizado de máquina já tenham alcançado um desempenho expressivo, a extração manual de características ainda exige muito trabalho. Os métodos existentes de aprendizado profundo utilizam arquiteturas complexas de redes neurais para alcançar maior acurácia, mas podem sofrer com sobreajuste, adaptabilidade insuficiente e baixa acurácia de reconhecimento. Para melhorar esse cenário, propõe-se um novo modelo leve, denominado classificador de fusão de características LSTM de fluxo duplo, baseado na concatenação de cinco características do domínio do tempo dos sinais de EMG com os dados brutos. Ambos são processados por redes neurais convolucionais unidimensionais e camadas LSTM para realizar a classificação. O método proposto consegue capturar eficazmente características globais dos sinais de EMG com uma arquitetura simples, o que implica menor custo computacional. Foi realizado um experimento com o conjunto de dados público DB1, composto de 52 gestos, no qual cada um dos 27 participantes repetiu cada gesto dez vezes. O modelo atingiu acurácia de 89,66%, comparável à de redes de aprendizado profundo mais complexas, e tempo de inferência de 87,6 ms por gesto, o que também permite sua aplicação em sistemas de controle em tempo real. O modelo proposto foi validado por um experimento individualizado por participante com 10 dos 40 participantes do conjunto DB2, alcançando acurácia média de 91,74%. Isso demonstra sua capacidade de fundir características do domínio do tempo e dados brutos para extrair informações mais eficazes do sinal de sEMG e selecionar uma rede apropriada, eficiente e leve para melhorar os resultados de reconhecimento.

Palavras-chave: aprendizado profundo; reconhecimento de gestos; LSTM de fluxo duplo; fusão de características.

1. Introdução

A eletromiografia (EMG) é um sinal biomédico capaz de refletir a ativação muscular e detectar a intenção de movimento humano. A EMG oferece vantagens específicas no controle de robôs e no reconhecimento de gestos em comparação com a captura tradicional de movimento ou com variáveis cinemáticas e cinéticas. Ela pode detectar a ativação muscular antes que a tensão muscular efetiva seja produzida, permitindo o controle de sistemas robóticos em tempo real, reduzindo atrasos computacionais e facilitando o movimento sincronizado e a realimentação. Por exemplo, Pratt et al. [1] demonstraram como a tecnologia avançada de detecção de sinais EMG pode aprimorar o funcionamento de um exoesqueleto robótico, permitindo um acionamento quase em tempo real. Além disso, a EMG pode detectar determinadas ativações musculares que não necessariamente provocam movimento, mas podem indicar rigidez articular ou outras alterações de estado interno. Borzelli et al. [2] investigaram como esses sinais podem modular a impedância articular sem produzir movimento efetivo, fornecendo informações sobre a intenção motora que não podem ser obtidas por dados cinéticos ou cinemáticos. Assim, a EMG não apenas aumenta a capacidade de resposta dos sistemas robóticos,

Publicado: 4 jun. 2024 · Recebido: 26 abr. · Revisado: 28 maio · Aceito: 31 maio

mas também aprofunda a compreensão das intenções do usuário. Essas capacidades tornam a EMG uma ferramenta valiosa para avançar no controle de robôs e melhorar as tecnologias de reconhecimento de gestos. Na prática, o sinal EMG representa a atividade elétrica das unidades motoras de um músculo e pode ser registrado por duas modalidades: EMG de superfície (sEMG) [3] e EMG intramuscular (iEMG). Recentemente, o uso de sinais biológicos que contêm muitas informações sobre a intenção de movimento humano surgiu como uma alternativa promissora no campo da interação humano-computador [4]. Como os sinais de sEMG podem ser obtidos de maneira conveniente com eletrodos fixados à superfície da pele, eles são amplamente utilizados em diferentes áreas, como diagnóstico médico, controle robótico e reconhecimento de gestos. Por isso, a sEMG recebeu atenção significativa e se tornou uma escolha popular entre pesquisadores.

Atualmente, o rápido avanço da interação humano-computador levou ao desenvolvimento de próteses inteligentes, que oferecem soluções promissoras para melhorar o cotidiano de pessoas com deficiência. A integração da eletromiografia de superfície (sEMG) às interfaces humano-computador ampliou significativamente as funcionalidades dessas próteses, permitindo o reconhecimento preciso de gestos. Os avanços em processamento de sinais e em tecnologias de aprendizado adaptativo melhoram a capacidade de adaptação do sistema a diferentes usuários, enfrentando os desafios da variabilidade dos sinais e aprimorando a precisão do controle de dispositivos protéticos [5]. Atualmente, há dois métodos amplamente empregados no reconhecimento de gestos: aprendizado de máquina (ML) e aprendizado profundo (DL). Em geral, o reconhecimento de gestos é dividido em quatro etapas: aquisição do sinal, pré-processamento, extração de características e classificação do sinal. Entre elas, a engenharia de extração de características é a mais importante, pois afeta diretamente os resultados do reconhecimento. A variabilidade dos dados de sEMG entre pessoas e a quantidade considerável de ruído tornam essa extração uma tarefa desafiadora [6]. Muitos pesquisadores procuram novas abordagens para extrair características de sEMG [7]. O aprendizado de máquina tradicional geralmente exige que as características sejam extraídas manualmente e fornecidas ao classificador. Em contrapartida, o aprendizado profundo pode capturar e identificar autonomamente características essenciais [8], melhorando o desempenho. Hoje, o uso de aprendizado profundo para reconhecimento de gestos é bastante difundido. A seguir, apresenta-se uma breve revisão desses dois métodos.

As características de sEMG podem ser agrupadas em características do domínio do tempo (TD), do domínio da frequência (FD) e combinações de ambos [9]. Nos métodos tradicionais, a extração de características é um dos aspectos mais importantes para os resultados de classificação. Na literatura, empregam-se algoritmos estatísticos, transformadas de Fourier ou wavelets, decomposição empírica de modos e diferentes técnicas para a extração de características. A combinação de características do domínio do tempo, da frequência ou de ambos pode servir como entrada do classificador. Entre os classificadores de aprendizado de máquina estão as máquinas de vetores de suporte (SVM) [10], florestas aleatórias (RF) [11] e os k vizinhos mais próximos (KNN).

Pizzolato et al. [12] extraíram características dos domínios do tempo e da frequência nos quatro conjuntos de dados NinaPro, obtendo resultados de aproximadamente 74% no reconhecimento de gestos da mão. Altimemy et al. [13] utilizaram os métodos LDA e SVM com a característica do domínio do tempo autorregressiva (AR) para classificar gestos da mão. Karnam et al. [14] propuseram utilizar um classificador KNN refinado em conjunto com características de energia combinadas do sinal de sEMG para classificar atividades da mão, alcançando acurácia máxima de 88,8%. Aslan et al. [15] empregaram um classificador SVM após extrair características pelos métodos de entropia de distribuição (DisEn) e função de distribuição acumulada normal (NCDF). Recentemente, Fatimah et al. [16] decompuseram sinais brutos de sEMG em bandas intrínsecas de Fourier, das quais extraíram características estatísticas para classificação com SVM e KNN. Conforme apresentado, apesar do desempenho notável do aprendizado de máquina, a extração manual das características pode ocasionar a perda de informações úteis relacionadas ao movimento. Wang et al. [17] extraíram seis características diferentes do domínio do tempo e escolheram a análise discriminante linear (LDA) como algoritmo de reconhecimento, alcançando acurácia de 98,4%.

Desde a aplicação bem-sucedida do aprendizado profundo no reconhecimento de imagens, pesquisadores tentam estender seu uso ao reconhecimento de gestos e obter um desempenho expressivo.

O aprendizado profundo caracteriza-se por sua estrutura de rede com múltiplas camadas e pela capacidade de aprender automaticamente representações hierárquicas complexas a partir dos dados. Essa abordagem é especialmente adequada a tarefas complexas, como reconhecimento de alvos e detecção de objetos.

Cheng et al. [18] utilizaram uma CNN para extrair características de imagem de sinais de sEMG do conjunto NinaPro DB1, realizando a classificação com acurácia de 82,54%. Wang et al. [19] criaram um mapa de características usando decomposição por wavelets e, em seguida, treinaram uma combinação de rede neural convolucional (CNN), memória de longo e curto prazo (LSTM) e mecanismo de atenção, atingindo 86,36% de acurácia no conjunto DB1. Jiang et al. [20] propuseram um novo modelo Residual-Inception-Efficient (RIE), baseado em convolução com fusão multiescala e mecanismo de atenção por canal, para classificar o conjunto DB1, alcançando 88,27%. Zefeng et al. [21] desenvolveram uma rede baseada em transformers, denominada transformador de convolução temporal em profundidade (TDCT), voltada ao reconhecimento de sinais esparsos de sEMG e testada em diferentes conjuntos de dados. Sahoo et al. [22] propuseram um modelo CNN 1D com menos parâmetros treináveis para classificar eficazmente os 52 gestos do NinaPro DB1. O modelo funcionou em um sistema de tempo real e ofereceu resposta rápida, reduzindo o tempo médio de inferência a 0,258 ms. Zhang et al. [23] aplicaram a curva de preenchimento de Hilbert para processar sinais de sEMG, gerando imagens que representam os domínios temporal e dos eletrodos. Essas imagens foram utilizadas como entradas para propor a rede Dual-View, que alcançou acurácia de 86,72% no NinaPro DB1.

De acordo com a literatura existente, é evidente que as técnicas de aprendizado profundo têm potencial para reduzir o trabalho necessário ao reconhecimento de gestos. Contudo, ainda há um longo caminho até a utilização de sinais de eletromiografia de superfície (sEMG) em aplicações de tempo real. As principais contribuições deste artigo são:

• **Arquitetura inovadora:** ao integrar camadas CNN 1D e Bi-LSTM, o modelo captura eficazmente tanto padrões sequenciais quanto informações de memória de longo prazo nos sinais de sEMG. A abordagem de fluxo duplo oferece uma estrutura mais simples, com menos parâmetros, maior acurácia e menor tempo de inferência, tornando-a adequada a aplicações de controle em tempo real.

• **Extração aprimorada de características:** a combinação de camadas convolucionais 1D e LSTM permite extrair características mais profundas e informativas dos dados de sEMG, melhorando significativamente os resultados de classificação.

• **Desempenho superior:** experimentos abrangentes com o conjunto DB1, que reúne 52 gestos diferentes, demonstram que o método proposto supera modelos conhecidos, incluindo um modelo baseado em transformer. Esses resultados confirmam a acurácia e a eficiência superiores do modelo de fusão de características com fluxo duplo.

O restante do artigo está organizado da seguinte forma: a Seção 2 resume os conceitos preliminares de cada módulo da rede proposta, e a Seção 3 descreve a metodologia. A Seção 4 apresenta os detalhes experimentais, incluindo o conjunto de dados, o processamento e os hiperparâmetros da rede. A Seção 5 reúne os resultados e a discussão. A conclusão e os trabalhos futuros aparecem na Seção 6.

2. Fundamentos preliminares

2.1. Redes neurais convolucionais unidimensionais (CNN 1D)

As redes neurais convolucionais (CNNs) tradicionais costumam ser aplicadas ao processamento de imagens, enquanto as CNNs 1D são utilizadas com dados organizados sequencialmente. O EMG é um sinal que pode ser entendido como uma sequência registrada ao longo do tempo.

A arquitetura típica de uma CNN compreende camadas de convolução, pooling, ativação e camadas totalmente conectadas. As camadas convolucionais aprendem padrões e características nos dados de entrada; uma ilustração de CNN 1D é apresentada na Figura 1. As camadas de pooling extraem as informações mais significativas para reduzir a dimensionalidade. À medida que o número de camadas convolucionais cresce, a rede se torna mais profunda. Contudo, um número excessivo de camadas pode produzir certo grau de sobreajuste e reduzir a capacidade de generalização da arquitetura.

Em comparação com CNNs 2D, a utilização de CNNs 1D reduz a dimensionalidade dos dados, captura padrões relevantes e melhora a eficiência computacional dos modelos. Normalmente, uma camada de normalização de lote (BN) é posicionada após as camadas convolucionais para aumentar a velocidade do treinamento, mitigando problemas de desaparecimento ou explosão dos gradientes durante esse processo [6].

Figura 1 - espaço reservado

Consulte a figura na página correspondente do original.

Figura 1. Ilustração de uma CNN 1D usando como exemplo um sinal de um único canal.

2.2. Memória de longo e curto prazo (LSTM)

O modelo de memória de longo e curto prazo (Long Short-Term Memory, LSTM) representa um tipo específico de rede neural recorrente (RNN), desenvolvido para superar dificuldades relacionadas ao desaparecimento e à explosão de gradientes. Essas estruturas consistem em células de memória capazes de conservar e modificar dados ao longo do tempo, reguladas por três portas: entrada, esquecimento e saída. Conforme mostra o diagrama da arquitetura LSTM na Figura 2, esse processo é executado pelas seis equações abaixo [24]. No modelo LSTM, uma porta de controle é utilizada para preservar o estado oculto atual dentro de uma célula de memória, considerando os estados ocultos anteriores [25]. Para aprimorar a capacidade de processamento de redes LSTM diante de dados complexos, pesquisadores passaram a empilhar múltiplas camadas LSTM e camadas LSTM bidirecionais.

$$\tilde{c}_t = \tanh(Wc\ x_t + Wc\ x_{t-1} + bc) \quad (1)$$

$$i_t = \delta(Wi\ x_t + Wi\ h_{t-1} + bi) \quad (2)$$

$$f_t = \delta(Wf\ x_t + Wf\ h_{t-1} + bf) \quad (3)$$

$$o_t = \delta(Wo\ x_t + Wo\ h_{t-1} + bo) \quad (4)$$

$$c_t = f_t \times c_{t-1} + i_t \times \tilde{c}_t \quad (5)$$

$$h_t = o_t \times \tanh(c_t) \quad (6)$$

Figura 2 - espaço reservado

Consulte a figura na página correspondente do original.

Figura 2. Diagrama da arquitetura LSTM.

Nas fórmulas, i_t representa a porta de entrada; f_t, a porta de esquecimento; o_t, a porta de saída; δ, a função sigmoide; W_x, os pesos dos neurônios da respectiva porta (x); h_{t-1}, a saída do bloco LSTM anterior (no instante t − 1); x_t, a entrada no instante atual; e b_x, os vieses das respectivas portas (x).

O modelo LSTM bidirecional utiliza duas direções para processar uma sequência: para a frente (do início ao fim) e para trás (do fim ao início). Esse método amplia significativamente o volume de dados ao qual a rede tem acesso, tornando-se uma ferramenta robusta para modelar dependências sequenciais entre palavras e expressões em ambos os sentidos da sequência. Além disso, ele é útil no processamento de entidades.

2.3. Concatenação

A camada de concatenação é frequentemente utilizada em CNNs para dois objetivos principais. Uma das abordagens consiste em gerar um mapa de características mais rico combinando saídas de várias camadas convolucionais. Essa técnica é exemplificada na conhecida arquitetura ResNet, em que blocos residuais empregam concatenação para capturar representações mais complexas de características [26]. Além disso, a concatenação é usada para criar mapas de características multiescala, integrando camadas convolucionais com diferentes tamanhos de kernel e permitindo obter informações em escalas variadas. Essa abordagem, fundamental para captar informações em diferentes escalas, é especialmente comum em tarefas de detecção de objetos e segmentação semântica.

3. Metodologia

Neste artigo, o objetivo é mapear características do sinal de EMG para classificar gestos da mão. A arquitetura geral do reconhecimento de gestos da mão (HGR) é apresentada na Figura 3. Primeiro, o sinal de EMG foi filtrado, normalizado e segmentado. Em seguida, foram extraídas cinco características do domínio do tempo de cada segmento. Dois fluxos, um contendo os dados brutos e outro as cinco características temporais, foram fornecidos a uma camada CNN 1D para capturar relações espaciais e de curta duração; depois, a uma camada de concatenação para reunir as características em uma única dimensão; e, finalmente, a duas camadas Bi-LSTM para aprender informações de memória de longo prazo usadas na classificação. Tanto as características projetadas manualmente quanto aquelas obtidas por técnicas de aprendizado profundo ajudam a obter diferentes tipos de informações codificadas para distinguir os gestos. Assim, um conjunto híbrido de características pode fornecer informações complementares que melhoram a classificação [27].

Figura 3 - espaço reservado

Consulte a figura na página correspondente do original.

Figura 3. Diagrama de HGR com as etapas incluídas na arquitetura proposta de fusão de características LSTM de fluxo duplo (imagem da aquisição de dados retirada de “Atzori 2014 [28]”).

3.1. Extração de cinco características baseadas no tempo

O artigo concentra-se na extração de cinco características do domínio do tempo para concatenação com o sinal bruto, formando dois fluxos de características de entrada para processamento posterior. O conjunto inclui f_MAV, f_ZC, f_SSC, f_WL e f_RMS, cujos detalhes aparecem na Tabela 1. Esse conjunto é calculado em cada segmento de uma execução, dividido de acordo com o tamanho da janela.

Como o número de amostras em cada execução é 500, os tamanhos de janela adotados no artigo são 200 ms (20 pontos amostrais) e 50 ms (5 pontos amostrais). Para explicar a criação do conjunto de características, considera-se a janela de 200 ms. O número N_f de valores de cada característica do domínio do tempo em cada execução é 25 (N_T dividido pelo número de amostras de uma janela). Como o conjunto de dados possui dez canais, o formato das características em cada execução é 25 × 5 × 10. Essa estrutura foi construída para facilitar a posterior integração com os dados brutos, que desempenham papel essencial na etapa de concatenação.

Tabela 1. Método de extração de características.

Nº	Descrição da característica	Expressão matemática (original)
1	RMS (raiz do valor quadrático médio): modelado como processo aleatório gaussiano de amplitude modulada, associado à contração de força constante sem fadiga [29].	$RMS = \sqrt{[(1/k)\ \Sigma(n=1\ldots k)\ x_n^2]}$
2	MAV (valor absoluto médio): média do valor absoluto do sinal EMG em uma janela de análise [30].	$\Sigma(n=1\ldots k-1)\ f(\lvert x_{n+1} - x_n\rvert)$
3	WL (comprimento da forma de onda): comprimento total da forma de onda EMG em uma janela de análise [31].	$(1/k)\ \Sigma(n=1\ldots k)\ \lvert x_n\rvert$
4	ZC (cruzamentos por zero): número de vezes que o sinal EMG muda de positivo para negativo, ou vice-versa [32].	$ZC = \Sigma(i=1\ldots N-1)\ sgn(x_i \times x_{i+1}) \cap \lvert x_i - x_{i+1}\rvert \geq$ limiar; $sgn(x)=1$ se $x \geq$ limiar; 0, caso contrário.
5	SSC (mudança de sinal da inclinação): informa sobre a frequência por meio do número de mudanças da inclinação de positiva para negativa, ou vice-versa [33,34].	$SSC = \Sigma(i=2\ldots N-1)\ f[(x_i - x_{i-1}) \times (x_i - x_{i+1})]$; $f(x)=1$ se $x \geq$ limiar; 0, caso contrário.

Expressões transcritas conforme a publicação original.

3.2. Modelo da rede

A estrutura contém dois fluxos que processam independentemente as cinco características do domínio do tempo e os dados brutos, como mostra a arquitetura na Figura 4. Os modelos dos fluxos de características e de dados brutos incluem camadas CNN 1D, normalização de lote, ativação e dropout. Essas camadas estão encapsuladas em uma estrutura distribuída no tempo (time-distributed), que processa o fluxo independentemente a cada passo temporal. Depois do processamento, suas saídas são agregadas por meio da camada de concatenação. Em seguida, a saída combinada passa pelas camadas LSTM bidirecionais e pelas camadas densas.

Para capturar características relevantes distintas dos sinais EMG, utilizam-se dois fluxos de camadas CNN 1D encapsulados em uma estrutura distribuída no tempo, para processar as cinco características temporais e os dados brutos. A principal diferença está na inserção de uma camada LSTM entre duas camadas CNN 1D, permitindo capturar a natureza sequencial do sinal bruto. A inclusão da camada LSTM no fluxo de dados brutos é motivada por sua capacidade de capturar informações sequenciais, condizentes com o EMG, que é inerentemente uma sequência. Cada fluxo de camadas convolucionais pode se concentrar em vários aspectos dos dados, adquirindo diferentes representações de características.

Após as camadas convolucionais, emprega-se uma camada de concatenação para combinar os conjuntos de mapas de características ao longo de uma nova dimensão, formando um vetor estendido que abrange uma variedade maior de propriedades dos dados. Os resultados da concatenação são encaminhados a duas camadas LSTM bidirecionais, projetadas para capturar dependências temporais tanto no sentido direto quanto no sentido inverso. Intuitivamente, reconhece-se amplamente que uma Bi-LSTM pode codificar informações temporais de longo prazo de forma mais eficaz do que uma LSTM unidirecional [24].

A saída das duas camadas Bi-LSTM é transformada em um tensor unidimensional e, em seguida, fornecida a uma camada totalmente conectada (FC), equipada com funções de ativação, dropout e normalização de lote para padronizar as saídas da camada densa. A camada final é uma camada densa com ativação softmax, projetada para classificação multiclasse. Neste estudo, a saída corresponde a 52 gestos da mão, conforme o diagrama de blocos mostrado na Figura 5.



Figura 4. Estrutura do modelo de fluxo duplo baseada em arquitetura LSTM e CNN.

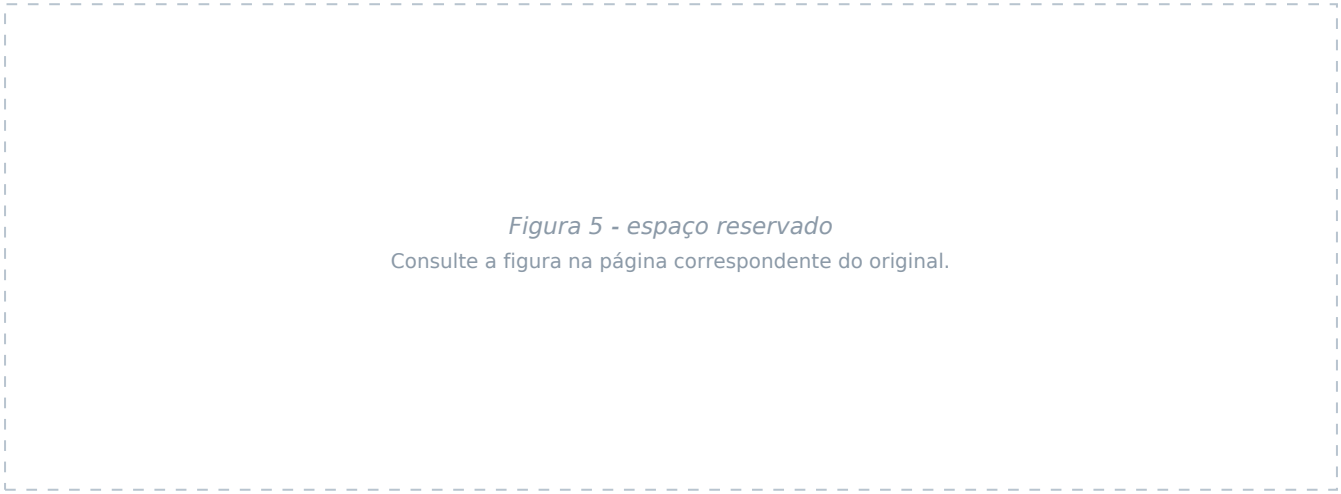


Figura 5. Diagrama de blocos do modelo de fluxo duplo.

No DB1, o número total de padrões de sEMG é N = S × N_a × R. Assim, neste artigo, N = 27 × 52 × 10 = 14.040, sendo S o número de participantes, N_a o número de gestos da mão e R o número de repetições de cada gesto por participante. O número de amostras de cada execução é N_T.

Tem-se N_T = N_s × T, em que N_T é o número de amostras de cada execução; T é a duração de uma execução; e N_s é a frequência de amostragem (amostras/s). Neste caso, N_T = 500. Conforme o tamanho do segmento, N_T é convertido em estruturas de dados pandas, utilizando TensorFlow, do início ao fim. Os formatos dos tensores em cada etapa da rede proposta estão apresentados na Tabela 2 (janela de 200 ms).

Tabela 2. Formatos de tensores obtidos durante a implementação e agregação dos dados.

Camada	Formato do tensor de características	Formato do tensor de dados brutos
Entrada	(25, 5, 10)	(25, 20, 10)
Conv1D	(25, 3, 256)	(25, 10, 256)
LSTM	NENHUM	(25, 10, 256)
Conv1D	(25, 2, 256)	(25, 5, 256)
Flatten	(25, 512)	(25, 1280)
Concatenado	(25, 1792)	
Bi-LSTM	(25, 200)	
Bi-LSTM	(25, 200)	
Flatten	(25, 200)	
Densa 1	(25, 512)	
Densa 2	(25, 52)	

4. Experimentos

Os experimentos foram realizados em um processador Intel(R) Core(TM) i7-3770K de 3,50 GHz (8 CPUs). A abordagem proposta foi implementada com o framework TensorFlow 2.2.0 e Python 3.8. Nesta parte da pesquisa, foi utilizado o conjunto de referência NinaPro DB1, disponível no repositório oficial do NinaPro [35].

4.1. Descrição do conjunto de dados

O conjunto NinaPro DB1 [28,36,37] reúne 52 gestos distintos (rótulos de 1 a 52), mostrados na Figura 6, executados por 27 participantes (20 homens e 7 mulheres, com idade de 28 ± 3,4 anos). Os gestos podem ser classificados em três grupos de movimentos: (a) flexão e extensão isoladas dos dedos; (b) flexão e extensão simultâneas de vários dedos e do punho; e (c) preensão de objetos, conforme apresentado na Tabela 3. A Figura 6 mostra os 52 rótulos e suas categorias correspondentes. Os dados de sEMG são adquiridos a uma taxa de amostragem de 100 Hz, por meio de dez eletrodos Otto Bock, com frequências de corte dos filtros ajustadas em 90 Hz e 450 Hz [28]. Cada participante realiza uma execução de cada movimento por cinco segundos, seguida de três segundos de repouso; esse ciclo é repetido dez vezes.

Tabela 3. Rótulos das atividades gestuais do NinaPro DB1.

Rótulo	Atividade gestual
1–12	Movimentos básicos dos dedos [28].
13–29	Configurações isométricas da mão e movimentos fundamentais do punho [28].
30–52	Movimentos de preensão e movimentos práticos [28].

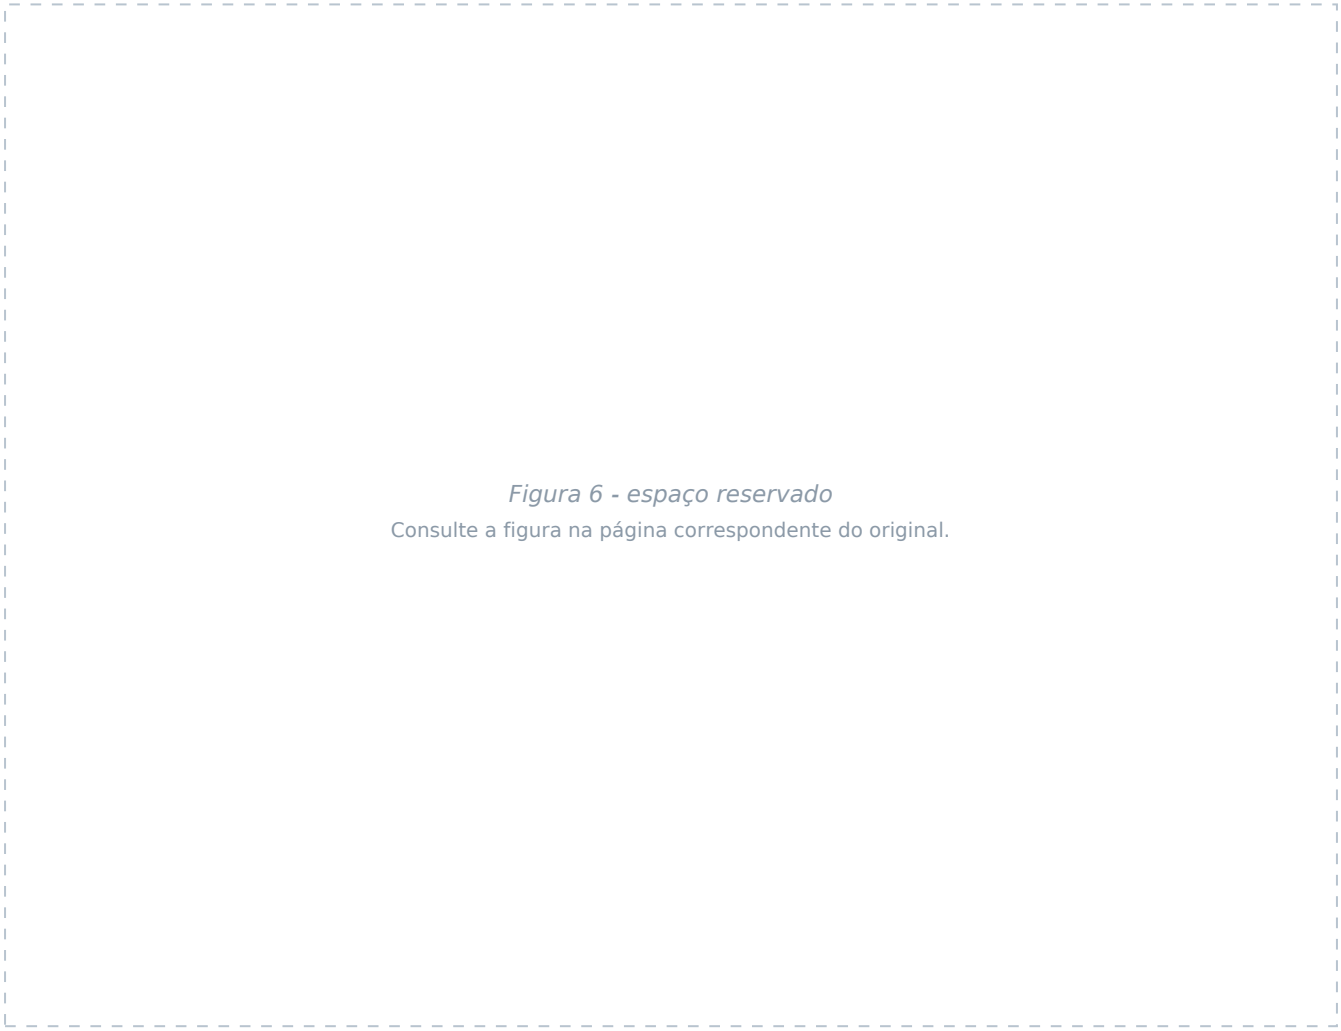


Figura 6. Os 52 movimentos da mão presentes no conjunto de dados NinaPro DB1 [28].

4.2. Processamento dos dados

As principais informações da eletromiografia de superfície (sEMG) concentram-se predominantemente na faixa de frequência de 20 a 200 Hz [38]. Antes de integrar o sinal bruto de sEMG, é essencial remover diversos tipos de ruído, incluindo o da rede elétrica e os ruídos ambientais, normalmente presentes no sinal. Antes da publicação da base NinaPro, os sinais foram sincronizados utilizando marcações temporais de alta resolução. Erros de sincronização de cada movimento foram corrigidos, e um filtro de 50 Hz foi empregado para atenuar o ruído da rede elétrica [12,28].

Na etapa de pré-processamento (Figura 3), os dados brutos de sEMG são inicialmente filtrados com um filtro passa-altas Butterworth para reduzir a interferência de ruído. Em seguida, os dados são padronizados pelo método Z-score (Equação 7), a fim de minimizar o impacto das variações nos dados.

$$z = (x - \mu) / \delta \quad (7)$$

Nessa equação, z é o valor normalizado, x é o valor original, μ é a média e δ é o desvio-padrão.

Um tamanho de janela é escolhido para segmentar os dados, normalmente visando facilitar o controle em tempo real. Estudos anteriores indicaram que um atraso de 300 ms atende aos requisitos [39]. O parâmetro de passo (stride) define quanto a janela avança a cada deslocamento. Nesta pesquisa, foram escolhidos tamanhos de janela de 200 ms e 50 ms, com o mesmo passo. A Figura 7 apresenta o sinal de um único canal de sEMG utilizando a técnica de janela deslizante.

Figura 7 - espaço reservado

Consulte a figura na página correspondente do original.

Figura 7. Segmentação dos dados de sEMG por janela deslizante.

4.3. Configurações da rede e treinamento do modelo

A arquitetura foi executada com TensorFlow 2.2.0, em conjunto com Python 3.8 e Matlab 2022b.

Os detalhes específicos de cada camada convolucional, tamanho de kernel, unidade LSTM e camada densa são apresentados na Tabela 2. Inicialmente, a taxa de aprendizado foi definida em 0,0001 nas primeiras 70 épocas; depois, foram aplicadas reduções em degraus por um fator de 0,1 para melhorar o desempenho do modelo. O tamanho do lote foi definido em 64. Os hiperparâmetros específicos utilizados para otimizar os resultados desta pesquisa são reunidos na Tabela 4.

Tabela 4. Hiperparâmetros ajustados do classificador de fusão de características LSTM de fluxo duplo.

Hiperparâmetro	Valor
Tamanho do lote	64
Taxa de aprendizado	0,0001
Otimizador	Adam: $\beta_1 = 0,9$; $\beta_2 = 0,999$
Ativação	Tanh, ReLU e softmax
Regularização do kernel	0,01
Normalização de lote	epsilon = 1×10^{-5}; momentum = 0,9
Número de épocas	500

4.4. Perda e otimização

A função de perda expressa a diferença entre os valores previstos e observados, servindo como medida para avaliar o desempenho do modelo. Para tarefas de classificação, utiliza-se com frequência a perda por entropia cruzada; sua expressão matemática é apresentada na Equação (8), na qual M representa o tamanho do lote, e y_i e ŷ_i representam, respectivamente, os rótulos esperado e observado.

$$\text{Perda} = -\Sigma(i=1\ldots M)\, y_i \cdot \log(\hat{y}_i) \quad (8)$$

Otimizadores são algoritmos ou técnicas empregados para minimizar a função de erro (função de perda) ou aumentar a eficiência do processo [40]. O algoritmo Adam incorpora médias ponderadas exponencialmente para aprimorar a descida do gradiente e funciona como uma extensão do algoritmo tradicional de otimização por gradiente descendente [41]. O Adam é preferido por sua maior capacidade de generalização. Por isso, foi selecionado para investigação neste artigo.

4.5. Avaliação da rede

O modelo de fluxo duplo é treinado e validado separadamente com dados distintos. A acurácia é o principal critério de avaliação para tarefas de classificação e é calculada da seguinte forma:

$$\text{Acurácia} = (\text{número de execuções classificadas corretamente} / \text{número total de execuções}) \times 100\% \quad (9)$$

A matriz de confusão fornece uma representação abrangente do desempenho preditivo. Assim, nesta pesquisa, a acurácia é utilizada para avaliar a eficácia da abordagem proposta no reconhecimento de sEMG, e os resultados são resumidos em uma matriz de confusão.

5. Resultados e discussão

Para validar a eficácia do modelo de fusão de características de fluxo duplo, foram realizados os seguintes experimentos: (a) diferentes formatos de entrada; (b) desativação do fluxo de entrada das cinco características do domínio do tempo, remoção da camada de concatenação e remoção da camada LSTM entre as camadas convolucionais 1D do fluxo de dados brutos. A seguir, o Modelo A representa a configuração sem dois fluxos de entrada, com janela de 200 ms; o Modelo B representa a configuração com dois fluxos de entrada e janela de 50 ms; e o Modelo C, a configuração com dois fluxos de entrada e janela de 200 ms.

5.1. Comparação entre diferentes formatos de entrada

Neste artigo, a análise foi realizada com dois formatos distintos de entrada para o conjunto DB1. Os resultados demonstram um alto grau de comparabilidade entre os diferentes tamanhos de janela.

Os gráficos apresentam as curvas de perda e acurácia ao longo das épocas de treinamento e validação para diferentes tamanhos de janela, como mostram as Figuras 8a,c e 9a,c. Como ilustrado, a rede executa eficazmente as tarefas de classificação e alcança acurácia expressiva. Com a janela de 200 ms, a acurácia de treinamento pode chegar a 100%, a acurácia de validação pode atingir 89,66%, e o tempo de inferência de cada gesto é 87,6 ms. Em comparação, com a janela de 50 ms, a acurácia de validação pode alcançar 85,291%, e o tempo de inferência é 70,4 ms. Após 100 épocas, a perda para os diferentes tamanhos de janela pode se estabilizar. Esse modelo demonstra o método de concatenação das características extraídas das características do domínio do tempo e dos dados brutos, usando camadas convolucionais 1D e LSTM para capturar informações relevantes do sinal de sEMG. A acurácia de classificação apresenta forte relação com o tamanho da janela; portanto, a escolha de uma janela adequada influencia o reconhecimento.

5.2. Comparação sem o modelo de fluxo duplo

Nesta parte, o experimento utilizou o modelo mostrado na Figura 10. Essa configuração possui um único fluxo de entrada de dados brutos, dispensando o fluxo adicional das cinco características do domínio do tempo e a camada LSTM normalmente empregada na análise dos dados brutos. Em seu lugar, aplica-se uma única camada convolucional 1D para extrair características dos dados brutos e reconhecer gestos. Conforme as Figuras 8b e 9b, a acurácia de treinamento pode alcançar 100%, enquanto a de validação atinge 86,69%, inferior à do modelo de fluxo duplo. Além disso, a perda se estabiliza, e o tempo de inferência é otimizado para 108 ms. Esses resultados reforçam o potencial do modelo proposto para melhorar o reconhecimento de gestos.

A matriz de confusão é utilizada para avaliar o desempenho de uma rede de classificação, mostrando a acurácia do classificador para cada gesto. No conjunto DB1, a semelhança entre vários gestos pode diminuir a acurácia de classificação. A Figura 11 mostra a matriz de confusão do modelo de fluxo duplo com janela de 200 ms, enquanto as Figuras 8d, 9d e 12 apresentam a tendência geral de acurácia, perda e comparação dos resultados. A figura evidencia que a estrutura de fluxo duplo não apenas alcança maior acurácia, como também oferece menor tempo de inferência. Essa melhoria é atribuída, em grande parte, ao método de fusão de características, que reúne características projetadas por meio de

camadas convolucionais 1D tanto das características do domínio do tempo quanto do sinal bruto. Esse método permite capturar características mais profundas e também características de sequências curtas dos sinais de sEMG. Essas características são fundidas e processadas pelas camadas Bi-LSTM para capturar informações de sequências de longo prazo. Essa combinação estrutural é especialmente eficaz para sinais sequenciais longos, como os de sEMG, podendo aumentar significativamente a acurácia da classificação e reduzir o tempo de inferência.

Figura 8 - espaço reservado
Consulte a figura na página correspondente do original.

Figura 8. Comparação da acurácia entre os modelos A, B e C (subfiguras a–d).

Figura 9 - espaço reservado
Consulte a figura na página correspondente do original.

Figura 9. Comparação da perda entre os modelos A, B e C (subfiguras a–d).

Figura 10 - espaço reservado

Consulte a figura na página correspondente do original.

Figura 10. Diagrama de blocos sem o modelo de fluxo duplo.

Figura 11 - espaço reservado

Consulte a figura na página correspondente do original.

Figura 11. Matriz de confusão do classificador de fusão de características de fluxo duplo.

Dados da diagonal da Figura 11 (classes 0–51): 0: 91,43; 1: 97,50; 2: 93,02; 3: 93,75; 4: 100; 5: 97,37; 6: 90,91; 7: 93,33; 8: 79,49; 9: 88,89; 10: 80,00; 11: 85,11; 12: 94,87; 13: 88,46; 14: 95,83; 15: 91,43; 16: 83,33; 17: 84,85; 18: 92,50; 19: 94,59; 20: 100; 21: 94,74; 22: 91,18; 23: 92,68; 24: 97,62; 25: 100; 26: 91,67; 27: 97,14; 28: 100,00; 29: 84,44; 30: 85,37; 31: 75,76; 32: 97,92; 33: 91,18; 34: 80,95; 35: 74,07; 36: 87,50; 37: 86,67; 38: 93,55; 39: 80,65; 40: 80,49; 41: 86,27; 42: 86,21; 43: 76,19; 44: 75,76; 45: 81,58; 46: 86,21; 47: 83,33; 48: 97,78; 49: 86,11; 50: 91,43; 51: 95,45.

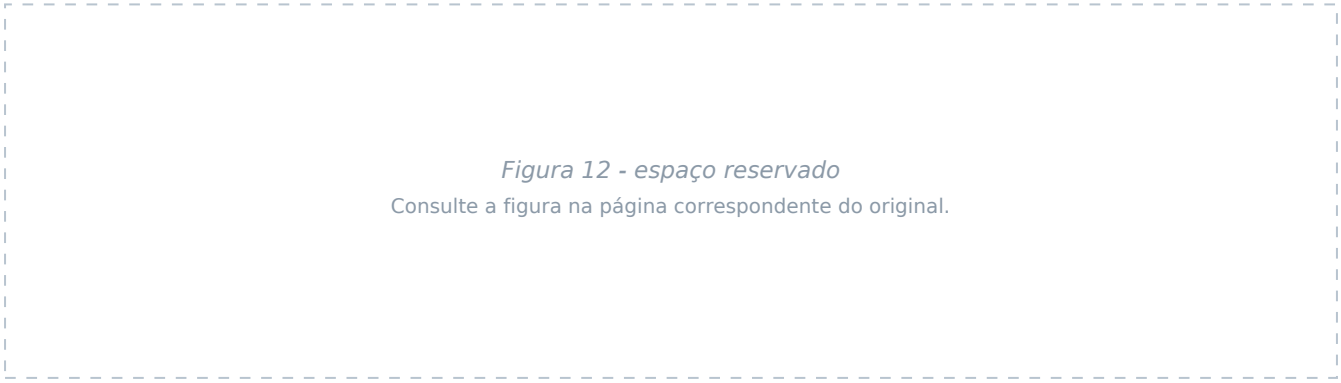


Figura 12. Comparação da acurácia de validação dos modelos A, B e C.

5.3. Validação com o conjunto de dados NinaPro DB2

Este estudo utiliza o conjunto de dados NinaPro DB2 [28] para validar o modelo proposto. O conjunto inclui 40 participantes executando 49 movimentos diferentes da mão e dos dedos, além de uma posição de repouso. Os dados de sEMG dos movimentos foram coletados por eletrodos de 12 canais, com taxa de amostragem de 2.000 Hz. Os movimentos são executados em seis repetições de cinco segundos, seguidas de três segundos de repouso.

Nesta pesquisa, foram escolhidos aleatoriamente 10 dos 40 participantes do DB2 para realizar um experimento individualizado por participante (subject-wise). Todos os procedimentos seguiram os estabelecidos para o DB1, incluindo pré-processamento, tamanho de segmento e ajuste fino dos hiperparâmetros do classificador. O modelo proposto foi avaliado em uma estrutura de análise individualizada por participante [24]. Nesse esquema, o modelo de fluxo duplo é treinado e validado separadamente utilizando dados específicos de cada pessoa. A abordagem busca reproduzir uma aplicação prática, na qual um modelo seria personalizado e adaptado a um usuário. Ao concentrar treinamento e validação nos dados de cada participante, o modelo pode aprender as características e variações próprias dos sinais de EMG daquela pessoa, resultando em reconhecimento de gestos mais preciso e confiável. A acurácia geral de classificação é calculada pela média dos resultados de todos os participantes, para avaliar de forma abrangente o desempenho do modelo. Os resultados detalhados são apresentados na Figura 13.

O modelo proposto apresenta bom desempenho em diferentes conjuntos de dados: a acurácia do modelo individualizado por participante ultrapassa 84%, com picos de 96%. A acurácia média entre os participantes alcança 91,74%.

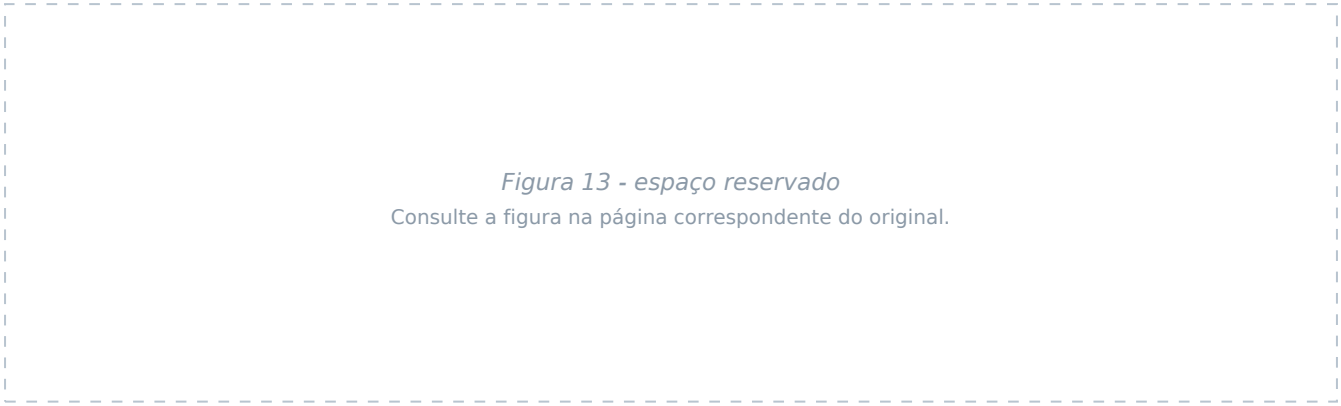


Figura 13. Acurácia de validação de dez participantes do conjunto de dados DB2.

5.4. Comparação dos resultados com trabalhos anteriores

Recentemente, muitos estudos investigaram o uso de sinais de EMG para reconhecimento de gestos e obtiveram bons resultados. Nesta pesquisa, a acurácia do modelo proposto é comparada com os resultados de estudos recentes que também utilizaram o conjunto NinaPro DB1. Os detalhes são apresentados na Tabela 5. Cabe destacar que a maioria das abordagens atuais

de aprendizado profundo para classificar gestos da mão, inclusive aquelas com CNNs, já alcançou resultados satisfatórios. Alguns pesquisadores combinam CNNs com outros métodos e superam redes baseadas exclusivamente em CNN. Além disso, redes baseadas em transformers que empregam as mesmas características elevaram a acurácia de classificação a um novo patamar, superior a 89%. Se estivessem disponíveis os tempos de inferência de todos os modelos listados, essa comparação seria especialmente valiosa para aplicações de tempo real.

Tabela 5. Comparação detalhada entre diferentes redes.

Classificador	Janela (ms)	Conjunto	Características	Acurácia
Florestas aleatórias [28]	200	DB1	RMS, MAV, WL, ZC, SSC e histograma	75,32%
KNN [14]	—	DB1	MAV, energias de segmentos temporais (TSE) e energias de bandas espectrais (SBE)	88,80%
MsCNN [42]	200	DB1	—	85,00%
EvCNN [43]	200	DB1	—	81,40%
CNN multivisão [44]	200	DB1	—	88,20%
CFF-RCNN [45]	250	DB1	—	88,87%
CNN 1D [22]	150	DB1	—	78,95%
Transformer [21]	100, 150 e 200	DB1	MAV, ZC, SSC, WL e RMS	89,43%
Proposto	50 e 200	DB1	MAV, ZC, SSC, WL e RMS	89,66%
Proposto	200	DB2	MAV, ZC, SSC, WL e RMS	91,74%

Este estudo apresenta uma estrutura projetada para extrair informações de diferentes perspectivas dos sinais EMG, incluindo os dados brutos e as características do domínio do tempo. O modelo proposto supera significativamente outros modelos que usam o mesmo conjunto de dados quanto à acurácia da classificação.

O desempenho aprimorado do modelo de fluxo duplo pode ser atribuído a vários fatores essenciais:

• O uso de uma camada de convolução 1D para processar simultaneamente características de dois fluxos distintos — características do domínio do tempo e dados brutos — permite capturar dependências espaciais e temporais.

• Uma abordagem de fusão de características por concatenação fornece a entrada a duas camadas LSTM bidirecionais, projetadas para reconhecer padrões temporais nos sentidos direto e inverso.

• No fluxo de dados brutos, uma camada LSTM integrada à convolução 1D captura as particularidades sequenciais dos dados, aumentando a acurácia preditiva do modelo.

6. Conclusões e perspectivas futuras

6.1. Conclusões

Esta pesquisa apresenta uma nova metodologia que utiliza uma camada convolucional de fluxo duplo para obter características tanto dos atributos do domínio do tempo quanto dos dados brutos. A técnica captura simultaneamente dependências espaciais e temporais nos dados, permitindo que a entrada processada seja encaminhada a camadas Bi-LSTM para aprimorar o reconhecimento de gestos da mão. O modelo é avaliado com o conjunto de referência NinaPro DB1 e alcança acurácia de 89,66%, superando os métodos de pesquisa anteriores que utilizam o mesmo conjunto, com tempo de inferência de 87,6 ms por gesto. Além disso, na validação com parte do conjunto DB2, o modelo demonstra eficiência considerável, com acurácia média de 91,74% em dez avaliações individualizadas por participante, ressaltando o potencial significativo do método proposto. Os resultados experimentais revelam que o modelo de fusão de características de fluxo duplo captura informações multiescala tanto das características do domínio do tempo quanto do sinal bruto. A integração de convolução 1D, camadas LSTM e técnicas de dropout produz uma melhoria expressiva no reconhecimento de gestos com sinais de EMG.

6.2. Perspectivas futuras

Trabalhos futuros buscarão aperfeiçoar o algoritmo proposto para melhorar o reconhecimento de gestos da parte superior do braço quando integrado a um exoesqueleto, além de simplificar a arquitetura da rede para diminuir os tempos de inferência em sistemas de controle em tempo real. Adicionalmente, está em desenvolvimento um sistema de coleta on-line de sinais de eletromiografia de superfície (sEMG), visando analisar instantaneamente a intenção de movimento humano. O objetivo é permitir o controle em tempo real de um exoesqueleto para auxiliar pessoas com limitações físicas. Por meio de técnicas avançadas de processamento de sinais, os sinais de sEMG podem ser convertidos em comandos executáveis pelo exoesqueleto, permitindo ao usuário realizar movimentos anteriormente difíceis. Essa inovação tecnológica representa um avanço importante na biomecânica e oferece possibilidades de melhorar a qualidade de vida de diferentes pessoas.

Contribuições dos autores: conceituação, K.Z. e Y.L.; metodologia, K.Z., Y.L., F.J.B. e M.F.P.; software, K.Z.; validação, K.Z. e Y.L.; análise formal, K.Z., Y.L. e F.J.B.; investigação, K.Z. e Y.L.; recursos, K.Z. e Y.L.; curadoria de dados, K.Z.; redação da versão original, K.Z.; revisão e edição do texto, K.Z., Y.L., F.J.B. e M.F.P.; visualização, K.Z.; supervisão, F.J.B. e M.F.P.; administração do projeto, M.F.P.; obtenção de financiamento, M.F.P. Todos os autores leram e concordaram com a versão publicada do manuscrito.

Financiamento: esta pesquisa recebeu apoio parcial do projeto ELMA: EXOSKELETON FOR LOAD MANIPULATION, sob a concessão PID2021-125579NB-I00, financiado pelo Ministério de Ciência e Inovação da Espanha.

Declaração do Comitê de Ética Institucional: não se aplica.

Declaração de consentimento informado: não se aplica.

Declaração de disponibilidade dos dados: o conjunto de dados pode ser acessado em http://ninapro.hevs.ch (acessado em 30 de maio de 2024).

Conflitos de interesse: os autores declaram não haver conflitos de interesse.

Abreviações

As seguintes abreviações são utilizadas neste manuscrito:

sEMG — eletromiografia de superfície
CNNs — redes neurais convolucionais
LSTM — memória de longo e curto prazo
HGR — reconhecimento de gestos da mão

Referências

1. Pratt, J.; Krupp, B.; Morse, C.; Collins, S. The RoboKnee: An exoskeleton for enhancing strength and endurance during walking. In Proceedings of the IEEE International Conference on Robotics and Automation, 2004. Proceedings. ICRA ’04. 2004, New Orleans, LA, USA, 26 April–1 May 2004; Volume 3, pp. 2430–2435. [CrossRef]

2. Borzelli, D.; Burdet, E.; Pastorelli, S.; D’Avella, A.; Gastaldi, L. Identification of the best strategy to command variable stiffness using electromyographic signals. J. Neural Eng. 2020, 17, 016058. . [CrossRef] [PubMed]

3. Farina, D.; Negro, F. Accessing the Neural Drive to Muscle and Translation to Neurorehabilitation Technologies. IEEE Rev. Biomed. Eng. 2012, 5, 3–14. [CrossRef] [PubMed]

4. Fu, R.; Zhang, B.; Liang, H.; Wang, S.; Wang, Y.; Li, Z. Gesture recognition of sEMG signal based on GASF-LDA feature enhancement and adaptive ABC optimized SVM. Biomed. Signal Process. Control 2023, 85, 105104. [CrossRef]

5. Yu, Z.; Zhao, J.; Wang, Y.; Linglong, H.; Wang, S. Surface EMG-Based Instantaneous Hand Gesture Recognition Using Convolutional Neural Network with the Transfer Learning Method. Sensors 2021, 21, 2540. [CrossRef] [PubMed]

6. Liu, X.; Zhang, M.; Wang, J.; Wang, X.; Liang, T.; Li, J.; Xiong, P.; Liu, X. Gesture recognition of continuous wavelet transform and deep convolution attention network. Math. Biosci. Eng. MBE 2023, 20, 11139–11154. [CrossRef] [PubMed]

7. Zhu, Z.; He, X.; Qi, G.; Li, Y.; Cong, B.; Liu, Y. Brain tumor segmentation based on the fusion of deep semantics and edge information in multimodal MRI. Inf. Fusion 2023, 91, 376–387. [CrossRef]

8. LeCun, Y.; Bengio, Y.; Hinton, G. Deep Learning. Nature 2015, 521, 436–444. [CrossRef] [PubMed]

9. Phinyomark, A.; Scheme, E. An Investigation of Temporally Inspired Time Domain Features for Electromyographic Pattern Recognition. In Proceedings of the 2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Honolulu, HI, USA, 18–21 July 2018; Volume 2018, pp. 5236–5240. [CrossRef]

10. Bian, F.; Li, R.; Liang, P. SVM based simultaneous hand movements classification using sEMG signals. In Proceedings of the 2017 IEEE International Conference on Mechatronics and Automation (ICMA), Takamatsu, Japan, 6–9 August 2017; pp. 427–432. [CrossRef]

11. Jia, R.; Yang, L.; Li, Y.; Xin, Z. Gestures recognition of sEMG signal based on Random Forest. In Proceedings of the 2021 IEEE 16th Conference on Industrial Electronics and Applications (ICIEA), Chengdu, China, 1–4 August 2021; pp. 1673–1678. [CrossRef]

12. Pizzolato, S.; Tagliapietra, L.; Cognolato, M.; Reggiani, M.; Müller, H.; Atzori, M. Comparison of six electromyography acquisition setups on hand movement classification tasks. PLoS ONE 2017, 12, e0186132. [CrossRef] [PubMed]

13. Al-Timemy, A.; Khushaba, R.; Bugmann, G.; Escudero, J. Improving the Performance Against Force Variation of EMG Controlled Multifunctional Upper-Limb Prostheses for Transradial Amputees. IEEE Trans. Neural Syst. Rehabil. Eng. Publ. IEEE Eng. Med. Biol. Soc. 2015, 24, 650–661. [CrossRef]

14. Karnam, N.K.; Turlapaty, A.C.; Dubey, S.R.; Gokaraju, B. Classification of sEMG signals of hand gestures based on energy features. Biomed. Signal Process. Control 2021, 70, 102948. [CrossRef]

15. Aslan, M. Normal Cumulative Distribution Function and Dispersion Entropy Based EMG Classification. Sak. Univ. J. Comput. Inf. Sci. 2020, 3, 325–333. [CrossRef]

16. Fatimah, B.; Singh, P.; Singhal, A.; Pachori, R. Hand movement recognition from sEMG signals using Fourier decomposition method. Biocybern. Biomed. Eng. 2021, 41, 690–703. [CrossRef]

17. Wang, Y.; Tian, Y.; Zhu, J.; She, H.; Yokoi, H.; Jiang, Y.; Huang, Q. A study on the classification effect of sEMG signals in different vibration environments based on the LDA algorithm. Sensors 2021, 21, 6234. [CrossRef]

18. Cheng, Y.; Li, G.; Yu, M.; Jiang, D.; Yun, J.; Liu, Y.; Liu, Y.; Chen, D. Gesture recognition based on surface electromyography-feature image. Concurr. Comput. Pract. Exp. 2020, 33, e6051. [CrossRef]

19. Wang, L.; Fu, J.; Zheng, B.; Zhao, H. Research on sEMG–based gesture recognition using the Attention-based LSTM-CNN with Stationary Wavelet Packet Transform. In Proceedings of the 2022 4th International Conference on Advances in Computer Technology, Information Science and Communications (CTISC), Suzhou, China, 22–24 April 2022; pp. 1–6.

20. Jiang, B.; Wu, H.; Xia, Q.; Xiao, H.; Peng, B.; Wang, L. Gesture Recognition Using sEMG Based on Multi-Scale Fusion Convolution and Channel Attention. SSRN 2023. [CrossRef]

21. Wang, Z.; Yao, J.; Xu, M.; Jiang, M.; Su, J. Transformer-based network with temporal depthwise convolutions for sEMG recognition. Pattern Recognit. 2023, 145, 109967. [CrossRef]

22. Krishnapriya S; Sahoo, J.P.; Ari, S. Surface Electromyography based Hand Gesture Signal Classification using 1D CNN. In Proceedings of the 2023 International Conference on Intelligent Systems, Advanced Computing and Communication (ISACC), Silchar, India, 3–4 February 2023; pp. 1–6. [CrossRef]

23. Zhang, Y.; Yang, F.; Fan, Q.; Yang, A.; Li, X. Research on sEMG-Based Gesture Recognition by Dual-View Deep Learning. IEEE Access 2022, 10, 32928–32937. [CrossRef]

24. Karnam, N.K.; Dubey, S.R.; Turlapaty, A.; Gokaraju, B. EMGHandNet: A hybrid CNN and Bi-LSTM architecture for hand activity classification using surface EMG signals. Biocybern. Biomed. Eng. 2022, 42, 325–340. [CrossRef]

25. Zhang, W.; Peng, G.; Li, C.; Chen, Y.; Zhang, Z. A New Deep Learning Model for Fault Diagnosis with Good Anti-Noise and Domain Adaptation Ability on Raw Vibration Signals. Sensors 2017, 17, 425. [CrossRef]

26. Bhure, S. Concatenation Operation in CNN. 2017. Available online: https://iq.opengenus.org/concatenation-operation-in-cnn (accessed on 30 May 2024).

27. Côté-Allard, U.; Campbell, E.; Phinyomark, A.; Laviolette, F.; Gosselin, B.; Scheme, E. Interpreting Deep Learning Features for Myoelectric Control: A Comparison With Handcrafted Features. Front. Bioeng. Biotechnol. 2020, 8, 158. [CrossRef]

28. Atzori, M.; Gijsberts, A.; Castellini, C.; Caputo, B.; Mittaz Hager, A.G.; Simone, E.; Giatsidis, G.; Bassetto, F.; Müller, H. Electromyography data for non-invasive, naturally-controlled Robotic hand prostheses. Nature 2014, 1, 140053. [CrossRef]

29. Kurniawan, S.R.; Pamungkas, D. MYO Armband sensors and Neural Network Algorithm for Controlling Hand Robot. In Proceedings of the 2018 International Conference on Applied Engineering (ICAE), Batam, Indonesia, 3–4 October 2018; pp. 1–6. [CrossRef]

30. Zecca, M.; Micera, S.; Carrozza, M.; Dario, P. Control of Multifunctional Prosthetic Hands by Processing the Electromyographic Signal. Crit. Rev. Biomed. Eng. 2002, 30, 459–485. [CrossRef]

31. Hudgins, B.; Parker, P.; Scott, R. A new strategy for multifunction myoelectric control. IEEE Trans.-Bio-Med. Eng. 1993, 40, 82–94. [CrossRef]

32. Zardoshti-Kermani, M.; Wheeler, B.; Badie, K.; Hashemi, R. EMG feature evaluation for movement control of upper extremity prostheses. IEEE Trans. Rehabil. Eng. 1995, 3, 324–333. [CrossRef]

33. Phinyomark, A.; Phukpattaranont, P.; Limsakul, C. Feature Reduction and Selection for EMG Signal Classification. Expert Syst. Appl. 2012, 39, 7420–7431. [CrossRef]

34. Micera, S.; Carpaneto, J.; Raspopovic, S. Control of hand prostheses using peripheral information. IEEE Rev. Biomed. Eng. 2010, 3, 48–68. [CrossRef]

35. Atzori, M.; Müller, H. The Ninapro database: A resource for sEMG naturally controlled robotic hand prosthetics. In Proceedings of the 2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Milan, Italy, 25–29 August 2015; pp. 7151–7154. [CrossRef]

36. Atzori, M.; Gijsberts, A.; Kuzborskij, I.; Elsig, S.; Mittaz Hager, A.G.; Deriaz, O.; Castellini, C.; Müller, H.; Caputo, B. Characterization of a Benchmark Database for Myoelectric Movement Classification. IEEE Trans. Neural Syst. Rehabil. Eng. 2015, 23, 73–83. [CrossRef]

37. Atzori, M.; Gijsberts, A.; Heynen, S.; Hager, A.G.M.; Deriaz, O.; van der Smagt, P.; Castellini, C.; Caputo, B.; Müller, H. Building the Ninapro database: A resource for the biorobotics community. In Proceedings of the 2012 4th IEEE RAS & EMBS International Conference on Biomedical Robotics and Biomechatronics (BioRob), Rome, Italy, 24–27 June 2012; pp. 1258–1265. [CrossRef]

38. Kong, F.; Deng, J.; Fan, Z. Gesture recognition system based on ultrasonic FMCW and ConvLSTM model. Measurement 2022, 190, 110743. [CrossRef]

39. Ding, Q.; Xiong, A.B.; Zhao, X.; Han, J. A review on researches and applications of sEMG-based motion intent recognition methods. Acta Autom. Sin. 2016, 42, 13–25. [CrossRef]

40. Musstafa. Optimizers in Deep Learning. 27 March 2021. Available online: https://medium.com/mlearning-ai/optimizers-indeep-learning-7bf81fed78a0 (accessed on 30 May 2024).

41. Pomerat, J.; Segev, A.; Datta, R. On Neural Network Activation Functions and Optimizers in Relation to Polynomial Regression. In Proceedings of the 2019 IEEE International Conference on Big Data (Big Data), Los Angeles, CA, USA, 9–12 December 2019; pp. 6183–6185. [CrossRef]

42. Wei, W.; Wong, Y.; Du, Y.; Hu, Y.; Kankanhalli, M.; Geng, W. A Multi-stream Convolutional Neural Network for sEMG-based Gesture Recognition in Muscle-Computer Interface. Pattern Recognit. Lett. 2017, 119, 131–138. [CrossRef]

43. Olsson, A.; Björkman, A.; Antfolk, C. Automatic discovery of resource-restricted Convolutional Neural Network topologies for myoelectric pattern recognition. Comput. Biol. Med. 2020, 120, 103723. [CrossRef] [PubMed]

44. Wei, W.; Dai, Q.; Wong, Y.; Hu, Y.; Kankanhalli, M.; Geng, W. Surface-Electromyography-Based Gesture Recognition by Multi-View Deep Learning. IEEE Trans. Biomed. Eng. 2019, 66, 2964–2973. [CrossRef] [PubMed]

45. Xu, P.; Li, F.; Wang, H.P. A novel concatenate feature fusion RCNN architecture for sEMG-based hand gesture recognition. PLoS ONE 2022, 17, e0262810. [CrossRef]

Nota de responsabilidade da editora: as declarações, opiniões e dados contidos nas publicações são de responsabilidade exclusiva de seus respectivos autores e colaboradores, e não da MDPI e/ou dos editores. A MDPI e/ou os editores não assumem responsabilidade por danos a pessoas ou propriedades decorrentes de ideias, métodos, instruções ou produtos mencionados no conteúdo.