BIOCYBERNETICS AND BIOMEDICAL ENGINEERING 42 (2022) 325–340

Disponível em www.sciencedirect.com

ScienceDirect

página da revista: www.elsevier.com/locate/bbe

Artigo original de pesquisa

EMGHandNet: Arquitetura híbrida CNN e Bi-LSTM para classificação de atividades da mão usando sinais de EMG de superfície

Naveen Kumar Karnam [a], *Shiv Ram Dubey* [b], *Anish Chand Turlapaty* [a,*], *Balakrishna Gokaraju* [c]

a Grupo de Análise de Biossinais, Departamento de Engenharia Eletrônica e de Comunicações, Instituto Indiano de Tecnologia da Informação, Sri City, Andhra Pradesh, Índia
b Laboratório de Visão Computacional e Biometria (CVBL), Departamento de Tecnologia da Informação, Instituto Indiano de Tecnologia da Informação, Allahabad, Uttar Pradesh, Índia
c Centro de Pesquisa Avançada em Visualização e Computação (ViCAR), Departamento de Ciência e Engenharia de Dados Computacionais, Universidade Estadual Agrícola e Técnica da Carolina do Norte, Greensboro, NC, Estados Unidos

INFO. DO ARTIGO

Histórico:
Recebido em 18 de setembro de 2021
Recebido em versão revisada
12 fev. 2022
Aceito em 13 de fevereiro de 2022
On-line em 26 fev. 2022

Palavras-chave:
CNN
LSTM bidirecional
Aprendizado profundo
Classificação de atividades da mão
Sinal de sEMG
Controle de exoesqueleto

R E S U M O

Recentemente, redes neurais convolucionais (CNNs) têm sido utilizadas para classificar atividades da mão a partir de sinais de eletromiografia de superfície (sEMG). Entretanto, o sinal sEMG apresenta esparsidade espacial devido à posição dos eletrodos nos músculos da mão e dependência temporal, pois a atividade é realizada ao longo de certo período. A CNN consegue extrair características espaciais, mas é limitada na extração de dependências temporais. Já a memória de longo e curto prazo (LSTM) busca codificar relações temporais em dados sequenciais. Assim, neste artigo, propomos a arquitetura EMGHandNet, baseada em uma CNN híbrida com LSTM bidirecional (Bi-LSTM), para codificar dependências entre canais e dependências temporais dos sinais sEMG na classificação de atividades da mão. Primeiro, as camadas CNN extraem características profundas dos sinais; depois, a Bi-LSTM processa os mapas de características para extrair informações sequenciais nos sentidos direto e reverso. Dessa forma, o modelo aprende informações entre canais e temporais bidirecionais de ponta a ponta. O modelo é treinado e testado em cinco conjuntos de referência: NinaPro DB1, NinaPro DB2, NinaPro DB4, BioPatRec DB2 e UCI Gesture. As acurácias médias de classificação para NinaPro DB1, NinaPro DB2, NinaPro DB4 e UCI Gesture são, respectivamente, 95,77%, 95,9%, 91,65% e 98,33%, representando melhorias de 4,42%, 12,2%, 18,65% e 1,33% em relação aos respectivos modelos do estado da arte. Para o BioPatRec DB2, observa-se desempenho comparável (91,29%). Os resultados experimentais e as comparações confirmam a superioridade do modelo proposto na classificação de atividades da mão a partir de sinais sEMG.

* Corresponding author at: Bio-Signal Analysis Group, Department of Electronics and Communication Engineering, Indian Institute of Information Technology, Sri City 517646, Andhra Pradesh, India.
E-mail address: anish.turlapaty@iiits.in (A.C. Turlapaty).

https://doi.org/10.1016/j.bbe.2022.02.005

0168-8227/© 2022 Nalecz Institute of Biocybernetics and Biomedical Engineering of the Polish Academy of Sciences. Published by Elsevier B.V. All rights reserved.

1. Introdução

A interação músculo-computador (MCI) é amplamente utilizada em próteses [1], controle robótico [2], sistemas de reconhecimento de língua de sinais (SLR) [3] e interação humano-máquina (HMI) [4]. A classificação de atividades da mão é um problema central na tecnologia MCI e abrange categorias como gestos da mão, preensão de objetos e movimentos da mão [5]. A classificação de gestos é empregada em jogos de computador, realidade virtual e cirurgias assistidas por robôs [6]. Uma cirurgia robótica exige especificação precisa da postura da mão robótica em relação ao corpo do paciente, bem como dos movimentos necessários.

Os gestos humanos podem ser identificados diretamente pela classificação de imagens de gestos [7] ou indiretamente por sinais correspondentes de eletromiografia de superfície (sEMG) [8]. Esta última abordagem apresenta enorme potencial para sistemas de controle de exoesqueletos e dispositivos protéticos. A classificação de sinais sEMG permite decodificar o movimento pretendido para controlar um braço robótico [9]. Especificamente, o sistema precisa decodificar a força, o torque e a direção que caracterizam os movimentos desejados da mão [10]. O mapeamento entre movimento e força correspondente foi estudado em [11] com arquiteturas ANN e LSTM.

Classificar a posição da mão durante a preensão de objetos tem aplicações diretas no controle de braços robóticos para tarefas de pegar e posicionar objetos [12,13]. Da mesma forma, classificar os movimentos da mão pode oferecer mais graus de liberdade ao braço de um exoesqueleto [14]. Este trabalho concentra-se na classificação das atividades da mão por sinais sEMG mediante métodos de reconhecimento de padrões. Tradicionalmente, classificam-se sinais sEMG com algoritmos de aprendizado de máquina (ML) e, mais recentemente, com métodos de aprendizado profundo (DL). A seguir, apresenta-se uma breve revisão.

1.1. Abordagens baseadas em aprendizado de máquina

Nas técnicas de aprendizado de máquina, classificar sinais sEMG exige extrair características, como as de domínio do tempo [15], de domínio da frequência [16] e de domínio tempo-frequência [15]. Shenoy et al. [17] classificaram oito movimentos da mão com uma máquina de vetores de suporte (SVM) linear, usando a raiz do valor quadrático médio (RMS) como característica, e controlaram um braço robótico com quatro graus de liberdade. Al-Timemy et al. [18] classificaram 15 movimentos de pessoas sem amputação e 12 de amputados com análise discriminante linear (LDA) e SVM, com características autorregressivas (AR). Shi et al. [19] empregaram valor absoluto médio (MAV), cruzamentos por zero (ZC), mudanças de sinal da inclinação (SSC) e comprimento da forma de onda (WL) para classificar posturas da mão com o classificador KNN e controlar uma mão biônica. Waris et al. [20] classificaram gestos obtidos com EMG de superfície e intramuscular durante sete dias e mostraram melhora de desempenho ao longo do tempo com a rede neural artificial (ANN), em comparação com KNN e SVM tradicionais. Tuncer et al. [21] extraíram características ternárias de sinais sEMG brutos. Momentos estatísticos foram usados como características para classificação com KNN e SVM cúbica. Mais recentemente, Fatimah et al. [22] decompuseram sinais sEMG em funções intrínsecas de banda de Fourier (FIBFs) e extraíram características estatísticas para classificação com SVM e KNN. A identificação de gestos pode ser aprimorada capturando informações de profundidade com um dispositivo Leap Motion, que melhora a reclassificação dos rótulos de gestos durante o treinamento [14]. Em [23], características baseadas em energia foram utilizadas com o classificador KNN fino para classificar gestos a partir de sinais sEMG. Uma limitação fundamental do aprendizado de máquina é a necessidade de projetar manualmente conjuntos de características relevantes, tarefa trabalhosa e possivelmente pouco precisa. Outra dificuldade é escolher um classificador ideal para as características selecionadas.

1.2. Abordagens baseadas em aprendizado profundo

Embora abordagens de aprendizado de máquina apresentem desempenho satisfatório na classificação de sinais sEMG, métodos de aprendizado profundo tornaram-se populares na literatura recente. Isso ocorre porque aprendem automaticamente características importantes [24] e tendem a oferecer desempenho superior. Sua aplicação à classificação de sEMG pode melhorar consideravelmente os mecanismos de controle de exoesqueletos. Nesta seção, revisamos técnicas recentes de aprendizado profundo para classificar sinais sEMG.

1.2.1. Abordagens com CNN

Em [25], Atzori et al. classificaram sinais sEMG dos conjuntos NinaPro DB1, DB2 e DB3 com uma CNN profunda de duas camadas convolucionais. Os autores mostraram melhora de desempenho de 2 a 5% em relação a classificadores tradicionais, como KNN, SVM, florestas aleatórias e LDA [26]. Entre as abordagens 2D, Geng et al. [27] representaram cada amostra de dimensão 1×10 (10 corresponde ao número de canais) como uma imagem instantânea e a forneceram à CNN. Mostraram que essas imagens possuem padrões semelhantes dentro de um mesmo ensaio e discriminativos entre ensaios diferentes. Wei et al. [28] dividiram segmentos das amostras em recortes de imagens e os processaram com uma arquitetura CNN paralela de múltiplos fluxos, analisando cada recorte. Obtiveram acurácias do estado da arte, porém com complexidade computacional de 10 a 20% maior que outras arquiteturas de referência. Em [29], desenvolveu-se um algoritmo evolutivo que gera a topologia da CNN, identificando o número apropriado de camadas, filtros e tamanho dos núcleos. Em [30], arquiteturas profundas que recebem EMG bruto, espectrograma ou transformada wavelet contínua (CWT) foram analisadas usando aprendizado por transferência. Qi et al. [31] usaram CNN 3D para classificar movimentos compostos da mão associados à escrita de dígitos. Betthauser et al. [32] implementaram um modelo de previsão de EMG com redes convolucionais temporais e demonstraram que

a previsão sequencial dos movimentos é superior à previsão quadro a quadro. Em [33], um único canal é selecionado aleatoriamente dos dados multicanais, obtendo-se acurácia próxima de 95% em um subconjunto do NinaPro DB2. Portanto, sinais sEMG podem ser classificados usando apenas um canal, solução eficiente para dispositivos com pouca memória.

1.2.2. Abordagens com RNN
Uma rede neural recorrente (RNN) é uma variação de rede neural adequada a dados sequenciais e temporais. Em [34], Koch et al. usaram ConvLSTM em cascata com LSTM para classificar sequências de gestos da mão. Em [35], implementou-se uma rede de duas etapas, com rede totalmente conectada seguida de RNN empilhada, para classificar sinais sEMG esparsos e de alta densidade (HD). Hu et al. [36] desenvolveram uma CNN-RNN com atenção capaz de classificar imagens sEMG. Em [37], comparou-se um modelo LSTM com uma LSTM profunda treinada por retropropagação (BP), utilizando classificação baseada na forma de onda. Em [38], uma arquitetura híbrida CNN-LSTM chamada redes convolucionais recorrentes de longo prazo (LRCNs) foi usada para reconhecimento de atividades e descrição de imagens e vídeos. Motivados por esse trabalho, Bao et al. [39] e Chen et al. [40] propuseram outras arquiteturas CNN-LSTM. Em [39], Bao et al. empregaram essa arquitetura conjunta para estimar ângulos do punho associados a quatro movimentos de seis indivíduos saudáveis. Chen et al. [40] aplicaram CNN e LSTM híbridas à classificação de gestos em um conjunto HD-sEMG, usando aprendizado por transferência. Observe que os autores de [40] usaram a LSTM apenas para os conjuntos-alvo.

1.3. Motivação para a arquitetura híbrida

A literatura mostra que arquiteturas CNN conseguem compreender características espaciais da atividade da mão, enquanto arquiteturas LSTM capturam informações temporais. Além disso, a Bi-LSTM supera a LSTM unidirecional ao aprender relações nos sentidos direto e inverso entre atividades e sinais sEMG de entrada. Por isso, propomos uma estrutura híbrida CNN e Bi-LSTM para aprender relações espaciais e temporais bidirecionais. Nossa abordagem difere das existentes em vários aspectos. O foco é classificar atividades da mão com CNN e Bi-LSTM, em vez de estimar ângulos, como em [39]. A arquitetura Bi-LSTM é usada em todos os experimentos, diferentemente de [40]. Realizamos o achatamento dos mapas de ativação antes da unidade Bi-LSTM, ao contrário da arquitetura em [40], que insere camadas densas entre CNN e LSTM, o que pode causar perda de informações temporais. Outra diferença é o tratamento das entradas: ao contrário de muitos trabalhos [28,29,36], não consideramos sobreposição de janelas.

1.4. Objetivos

O objetivo principal deste estudo é classificar atividades da mão humana a partir de sinais sEMG. O objetivo específico é identificar as seguintes características de um modelo de aprendizado profundo para obter desempenho ideal de classificação: (1) um formato adequado para os dados de entrada; (2) o número de camadas convolucionais e/ou LSTM; (3) um conjunto adequado de hiperparâmetros; e (4) técnicas apropriadas de pré-processamento dos sinais sEMG.

1.5. Contribuições

As principais contribuições deste trabalho são:

1. Demonstramos uma arquitetura EMGHandNet híbrida, baseada em CNN e Bi-LSTM, para classificar atividades da mão humana com sinais sEMG.
2. O método proposto explora, respectivamente, o aprendizado de características entre canais e características temporais por meio de camadas convolucionais 1D e Bi-LSTM. Em particular, relações espaciais e temporais de curto prazo são codificadas pelas camadas convolucionais, enquanto as relações temporais de longo prazo são aprendidas pela Bi-LSTM.
3. Realizamos experimentos rigorosos com cinco conjuntos sEMG de referência, para classificar movimentos da mão. Também analisamos o impacto do método sob diferentes perspectivas e comparamos seu desempenho com métodos recentes de aprendizado profundo.

O restante do artigo está organizado assim: a Seção II apresenta os fundamentos necessários; a Seção III descreve a metodologia proposta; a Seção IV detalha a configuração experimental; a Seção V apresenta os resultados; e a Seção VI traz conclusões e possibilidades futuras.

2. Fundamentos

Nesta seção, ilustramos o funcionamento básico das CNNs e LSTMs.

2.1. Redes neurais convolucionais (CNN)

As CNNs são comumente usadas para extrair características de imagens [41]. Uma CNN possui camadas de convolução, ativação e pooling. Na camada convolucional (conv), a entrada é convoluída com os pesos do filtro. O número de linhas do núcleo define seu tamanho; o número de colunas corresponde ao número de canais dos dados na primeira camada. Nas demais camadas, corresponde ao número de filtros. A Fig. 1 ilustra uma convolução 1D. Considere um sinal sEMG de dois canais, como na Fig. 1: o núcleo é um filtro bidimensional com duas colunas e a primeira saída é calculada como $y_0 = a_0 \cdot k_0 + a_1 \cdot k_1 + b_0 \cdot k_2 + b_1 \cdot k_3$. As outras saídas são obtidas deslocando o núcleo verticalmente (na direção do tempo). Assim, cada filtro produz um vetor. Os vetores de saída dos filtros são concatenados por colunas para formar um mapa de características 2D, processado pelas camadas convolucionais seguintes.

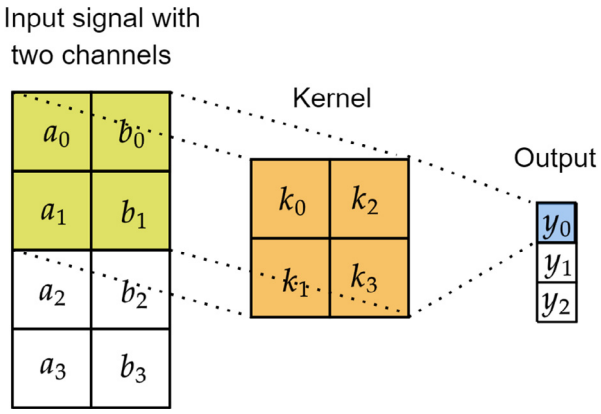


Fig. 1 – Ilustração da convolução 1D com um exemplo de dois canais.

As camadas convolucionais são empilhadas até se obterem características abstratas dos sinais. Na camada de ativação, a entrada é transformada por uma função não linear, como tanh(·) ou ReLU. A camada de pooling reduz a dimensionalidade do mapa de características. O max-pooling seleciona as características mais salientes. Por fim, a função softmax converte a saída em probabilidades (escores de classificação).

2.2. Memória de longo e curto prazo (LSTM)

Redes neurais recorrentes (RNNs) analisam sequências de dados nas quais a previsão depende de valores calculados anteriormente. São comumente usadas em dados de texto, fala e sequências de DNA, nos quais a informação atual depende dos instantes anteriores. Entretanto, problemas de gradientes que desaparecem ou explodem nas RNNs [42] limitam seu uso com sequências longas. Por isso, usam-se redes de memória de longo e curto prazo (LSTMs) [43]. Numa LSTM, uma porta de controle mantém o estado oculto atual em uma célula de memória, com base nos estados ocultos anteriores. As previsões de saída são codificadas com base nesses estados. A saída codificada de cada camada LSTM é acrescentada recursivamente para formar um vetor completo de características. A LSTM bidirecional (Bi-LSTM) utilizada neste trabalho recebe sequências e gera estados ocultos para cada instante, conforme a Fig. 2. Ela considera a sequência tanto no sentido direto quanto no inverso, codificando e concatenando suas características.

3. Metodologia

3.1. Formulação do problema

O número total de padrões sEMG em um conjunto é N = S × N_A × R, em que S é o total de participantes, N_A é o número de atividades distintas da mão e R é o número de repetições por participante. O conjunto completo de sEMG pode ser representado por:

$$\mathbf{x} = \{\mathbf{x}_n\}_{n=1}^{N} \tag{1}$$

em que cada observação x_n contém múltiplos canais:

$$\mathbf{x}_n = \{\mathbf{x}_{n,m}\}_{m=1}^{N_C},\ n = 1, \cdots, N \tag{2}$$

e N_C é o número de canais (provenientes de eletrodos diferentes); cada canal contém um vetor:

$$\mathbf{x}_{n,m} = \{x_{n,m}(i)\}_{i=1}^{N_T} \tag{3}$$

em que N_T = N_s × T é a quantidade de valores em um ensaio de duração T, e N_s é a frequência de amostragem (amostras/s).
O objetivo é mapear sinais sEMG para a atividade correspondente (a, rótulo-alvo), o que pode ser expresso por:

$$f\{\mathbf{x}_n\} \rightarrow \alpha \tag{4}$$

A função de mapeamento em (4) pode ser implementada por um classificador de aprendizado de máquina ou profundo. Para o mapeamento, são necessárias características apropriadas que representem as relações cinemáticas inversas subjacentes entre sinais sEMG e atividade realizada. A extração de características e o mapeamento são feitos pelo modelo híbrido de aprendizado profundo descrito a seguir (Fig. 3).

3.2. Modelo híbrido EMGHandNet

O esquema de implementação da EMGHandNet híbrida, baseada em CNN e Bi-LSTM, é ilustrado na Fig. 3; sua arquitetura interna aparece na Fig. 4. Os sinais sEMG são pré-processados, segmentados adequadamente e fornecidos à arquitetura profunda para classificação. A EMGHandNet possui quatro camadas CNN unidimensionais (1D) com um wrapper de distribuição temporal, seguidas de duas camadas Bi-LSTM e, por fim, duas camadas densas, conforme a Fig. 4. A camada densa final produz as categorias de atividades da mão. O modelo aprende o mapeamento entre a atividade neuromuscular (sinais sEMG) e a cinemática do membro. Assim, classifica as atividades sem depender de modelos neuromecânicos teóricos (por exemplo, equações diferenciais). Esse aprendizado do mapeamento cinemático baseado em ML é demonstrado em [44–47].
A primeira etapa é organizar e pré-processar os dados EMG para a CNN. O número de amostras N_T de cada ensaio é fatorado como:

$$\{S_L, T_S\} = fact(N_T) \tag{5}$$

em que S_L é o número de subsequências, T_S é o número de instantes por subsequência e fact(N_T) indica a fatoração de N_T de modo que N_T = S_L × T_S. Escolhe-se T_S como o menor valor positivo possível. Os rótulos das classes são codificados em one-hot para calcular a perda de entropia cruzada do problema multiclasse. O formato inicial N_T × N_C é reorganizado em S_L × T_S × N_C pelo método de fatoração (5). Esses dados 3D são separados em treino e teste e enviados a camadas CNN 1D. A dimensão de saída N_o de cada camada com núcleo de tamanho k é dada por:

$$N_o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1 \tag{6}$$

em que i = entrada, s = passo e p = preenchimento dado por p = ⌊k/2⌋.

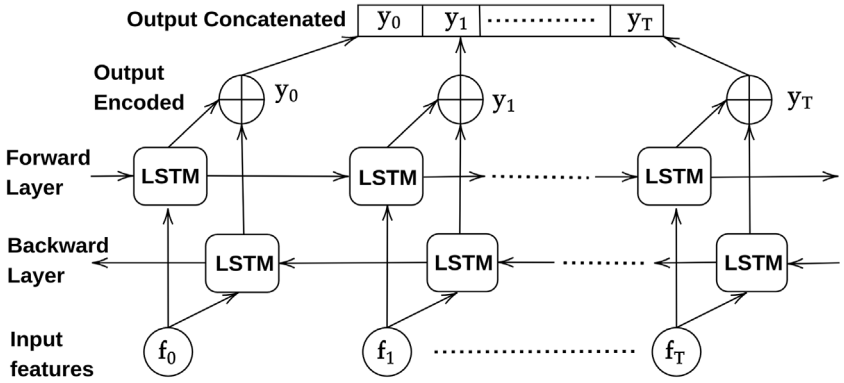


Fig. 2 – Diagrama de blocos da LSTM bidirecional.

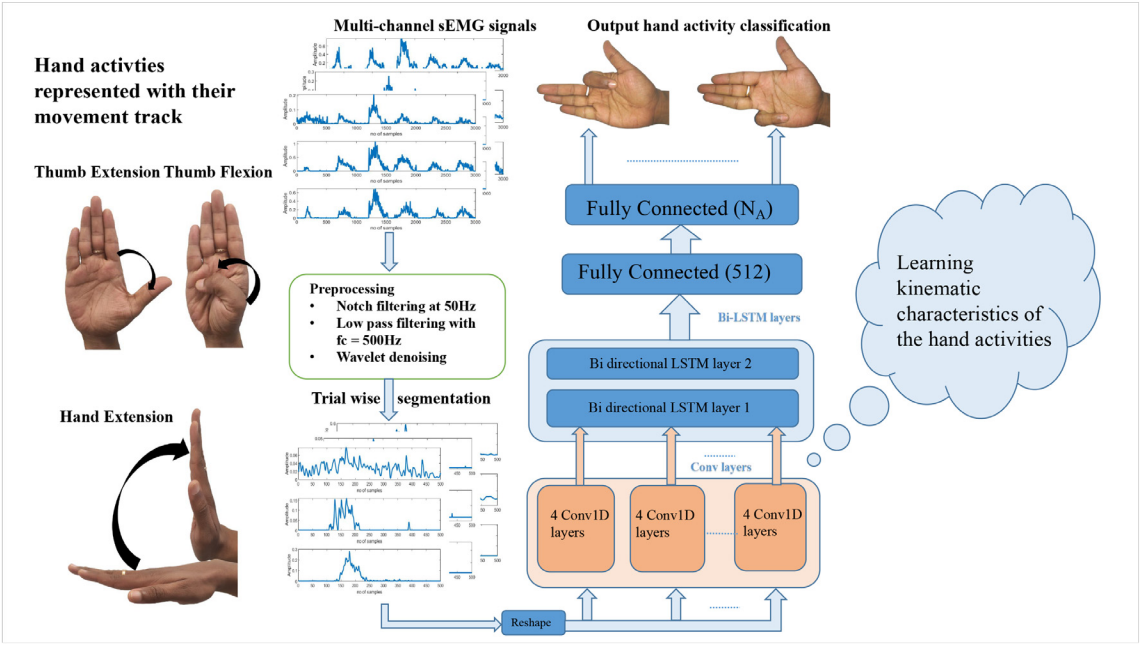


Fig. 3 – Diagrama de blocos das etapas de aprendizado da arquitetura híbrida EMGHandNet baseada em CNN e Bi-LSTM.

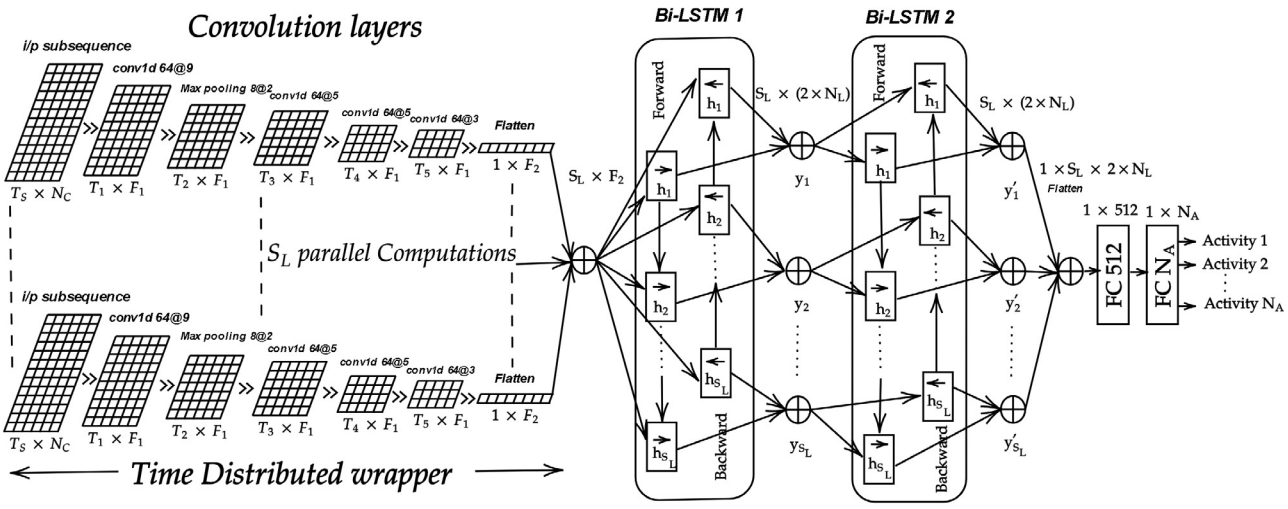


Fig. 4 – Vista detalhada da arquitetura híbrida EMGHandNet baseada em CNN e Bi-LSTM.

Tabela 1 – Categorias de ações mapeadas para o controle de braços robóticos.

Categoria de ação	Controle do braço robótico ou exoesqueleto	
Gestos	Controlar os dedos do braço robótico e da mão biônica	[50,51]
Movimentos do punho	Controlar os graus de liberdade	[51]
Preensão de objetos	Guiar o braço para pegar e posicionar objetos	[12,13]
Movimentos da mão	Oferecer vários graus de liberdade ao exoesqueleto	[14]

O mapa de características obtido é processado por mais três camadas convolucionais, produzindo um vetor de saída de dimensão $T_5 \times F_1$, que é achatado em $1 \times F_2$. Os conjuntos de características calculados em S_L fluxos paralelos são concatenados num arranjo $S_L \times F_2$, utilizado como entrada em uma pilha de camadas Bi-LSTM. Intuitivamente, a Bi-LSTM codifica melhor informações temporais de longo prazo do que uma LSTM unidirecional. Isso porque a LSTM direta codifica a sequência do início ao fim do ensaio, e a reversa, do fim ao início. A camada reversa representa melhor a postura final da atividade, enquanto a direta permite prever seu movimento intermediário, melhorando a acurácia da classificação. A previsão de movimentos intermediários pela camada reversa também reduz o número de possibilidades para os movimentos seguintes, favorecendo a separação no espaço abstrato de características e minimizando a ambiguidade entre classes. A saída da Bi-LSTM para todas as subsequências tem dimensão $S_L \times 2 \times N_L$; ela é achatada e processada por duas camadas densas. A última camada usa softmax para obter probabilidades de cada classe de atividade da mão.

4. Configuração experimental

4.1. Conjuntos de dados

Nesta seção, discutimos brevemente os cinco conjuntos públicos de referência usados nos experimentos: NinaPro DB1, NinaPro DB2, NinaPro DB4, BioPatRec DB2 e UCI Gesture. Nas sessões de medição, sensores sEMG foram posicionados sobre diferentes músculos dos membros superiores: flexor radial do carpo, flexor ulnar do carpo, extensor dos dedos, extensor radial curto do carpo e palmar longo [48]. Os conjuntos reúnem atividades da mão classificadas em gestos, movimentos do punho, preensão de objetos e movimentos da mão. A Tabela 1 mostra categorias que podem ser mapeadas para o controle de braços robóticos ou exoesqueletos. Presume-se que a diferença entre gestos estáticos e dinâmicos seja a velocidade angular dos dedos durante a atividade [49]. Em ações estáticas, o ângulo entre os dedos não varia durante a execução; em ações dinâmicas, varia. A posição da mão pode mudar em ambos os casos. Com base nessa suposição, os conjuntos contêm somente ações estáticas. Mais detalhes são apresentados nas referências citadas abaixo.

A seguir, apresenta-se uma breve descrição de cada conjunto analisado:

1. NinaPro DB1 [26]: reúne sinais sEMG de 27 participantes em atividades agrupadas nos exercícios A, B e C. O exercício A contém flexão e extensão de dedos isolados. O B inclui flexão e extensão de vários dedos e movimentos do punho. O C consiste em segurar objetos domésticos. Cada atividade dura 5 s, seguida de 3 s de repouso, e é repetida dez vezes.
2. NinaPro DB2 [26]: reúne sinais sEMG de 40 participantes realizando gestos com os dedos e preensão de objetos. As 49 classes são agrupadas nos exercícios B, C e D. Os exercícios B e C são iguais aos do NinaPro DB1. O D contém nove padrões de força obtidos quando os dedos pressionam sensores de força.
3. NinaPro DB4 [52]: sinais sEMG de dez participantes. As atividades são as mesmas do NinaPro DB1; a diferença é a maior frequência de amostragem.
4. BioPatRec DB2 [53]: contém 26 movimentos da mão de 17 participantes. Inclui seis movimentos básicos (abrir/fechar, pronação/supinação da mão e flexão/extensão do punho) e 20 combinações desses movimentos. Cada movimento dura 3 s, seguidos de 3 s de repouso.
5. UCI Gesture [54]: contém sete movimentos da mão de 36 participantes: mão fechada em punho, flexão e extensão do punho, desvios radial e ulnar do punho, palma estendida e repouso. Como nem todos os participantes executam o gesto da palma estendida, foram consideradas apenas as seis primeiras classes na classificação.

4.2. Pré-processamento e preparação dos dados

Como resumido na Tabela 2, cada ensaio x_n recebe um pré-processamento diferente conforme o conjunto. O pré-processamento é realizado no MATLAB R2020 para gerar arquivos de treino e teste. Como os sinais sEMG são contaminados por componentes indesejados, como ruído da rede elétrica e do receptor, são usadas três etapas: (a) filtragem do ruído de rede em 50 Hz para remover interferência da fonte de energia; (b) filtro passa-baixas Butterworth de primeira ordem

Tabela 2 – Etapas de pré-processamento de cada conjunto de dados.

Etapa de processamento	NinaPro DB1	NinaPro DB2	NinaPro DB4	BioPatRec DB2	UCI Gesture
Filtragem do ruído elétrico de 50 Hz	Não aplicado	Aplicado	Aplicado	Não aplicado	Não aplicado
Filtragem passa-baixas com corte frequência fc = 500 Hz	Não aplicado	Aplicado	Aplicado	Não aplicado	Não aplicado
Remoção de ruído por wavelets	Aplicado	Aplicado	Aplicado	Aplicado	Aplicado

Tabela 3 – Características dos conjuntos de dados e configuração dos experimentos numéricos.

Parâmetro	NinaPro DB1	NinaPro DB2	NinaPro DB4	BioPatRec DB2	UCI Gesture
Nº de participantes (S)	27	40	10	17	36
Nº de classes (N_A)	52	49	52	26	6
Nº de canais (N_C)	10	12	12	8	8
Nº de repetições (R)	10	6	6	3	4
Frequência de amostragem (N_s) (amostras/s)	100	2000	2000	2000	1000
Extensão do ensaio (N_T)	500	10000	10000	6000	1500
Duração da atividade (s)	5	5	5	3	3
Tempo de repouso (s)	3	3	3	3	3
Tipo de sensor	Otto Bock	Delsys Trigno Wireless	Cometa MiniWave	Bipolar Silver Electrodes	MYO Thalmic bracelet
Total de padrões (N)	14040	11760	3120	1326	864
Padrões por classe	270	240	60	51	24
Padrões treino (agregado)	9828	7840	2080	884	648
Padrões teste (agregado)	4212	3920	1040	442	216
Padrões treino (individual)	364	196	208	52	18
Padrões teste (individual)	156	98	104	26	6
Ensaios de treino	1,3,4, 6,8,9, 10	1,3,4, 6	1,3,4, 6	1,3	1,3,4
Ensaios de teste	2,5,7	2, 5	2,5	2	2

com frequência de corte de 500 Hz (pois o sinal sEMG situa-se na faixa de 20 a 380 Hz); e (c) remoção de ruído por wavelets de ordem 8, usando a wavelet-mãe Symlet. As etapas são aplicadas conforme as necessidades de cada conjunto. No NinaPro DB1, como o ruído de rede em 50 Hz já foi filtrado, aplica-se apenas a remoção de ruído por wavelets. Como os dados foram amostrados a 100 Hz, não é necessário filtro passa-baixas com corte em 500 Hz. Para NinaPro DB2 e DB4, amostrados a 2 kHz, aplicam-se filtro de ruído em 50 Hz e filtro passa-baixas em 500 Hz; os dados filtrados também passam por remoção de ruído por wavelets. O BioPatRec DB2 já apresenta filtragem do ruído de 50 Hz e passa-banda entre 20 e 400 Hz; portanto, não requer outras filtragens. Os dados UCI Gesture também já estão filtrados e recebem apenas remoção de ruído por wavelets.

Em determinado ensaio, amostras que excedam N_T são truncadas; se houver menos de N_T amostras, adicionam-se zeros (*zero padding*). Os dados são divididos por ensaio em 70% para treinamento, conforme a Tabela 3, e 30% para teste [29]. Os conjuntos de treino e teste são padronizados por canal para obter média zero e variância unitária. Os arquivos são convertidos em DataFrames do pandas com backend TensorFlow. A Tabela 4 mostra os formatos dos tensores de cada camada.

4.3. Configuração da rede e treinamento do modelo

A EMGHandNet é implementada com os seguintes parâmetros: a taxa de aprendizado (lr) é inicializada em 10^{-3} e o tamanho do lote (*batch*) é 16. Os hiperparâmetros ajustados para melhorar o desempenho aparecem na Tabela 5. O número de filtros e o tamanho do núcleo de cada camada convolucional estão na Fig. 4; por exemplo, conv1d 64@9 significa 64 filtros de tamanho 9. A EMGHandNet é treinada e testada separadamente para cada conjunto, e a acurácia da classificação correspondente é calculada como:

$$\text{Acurácia} = (\text{nº de ensaios corretamente classificados} / \text{nº total de ensaios}) \times 100. \quad (7)$$

Os experimentos foram executados em um computador com GPU Nvidia Quadro RTX 6000 de 24 GB de memória. O modelo foi implementado com o framework TensorFlow 2.2.0 em Python.

5. Resultados e discussão

Os modelos a seguir são treinados e testados nos cinco conjuntos de referência já mencionados.

1. EMGHandNet: arquitetura híbrida CNN e Bi-LSTM proposta.

Tabela 4 – Formatos de tensores obtidos durante a implementação, no esquema de dados agregados. Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento temporal de 50 ms).

Formato do tensor	Valores do NinaPro DB1	Valores do NinaPro DB2 and NinaPro DB4	Valores do BioPatRec DB2	Valores do UCI Gesture
$N_T \times N_C$	500×10	10000×12	6000×8	1500×8
$S_L \times T_S \times N_C$	$25 \times 20 \times 10$	$25 \times 400 \times 12$	$15 \times 400 \times 8$	$30 \times 50 \times 8$
$S_L \times T_1 \times F_1$	$25 \times 10 \times 64$	$25 \times 200 \times 64$	$15 \times 200 \times 64$	$30 \times 25 \times 64$
$S_L \times T_2 \times F_1$	$25 \times 2 \times 64$	$25 \times 97 \times 64$	$15 \times 97 \times 64$	$30 \times 9 \times 64$
$S_L \times T_3 \times F_1$	$25 \times 1 \times 64$	$25 \times 49 \times 64$	$15 \times 49 \times 64$	$30 \times 5 \times 64$
$S_L \times T_4 \times F_1$	$25 \times 1 \times 64$	$25 \times 25 \times 64$	$15 \times 25 \times 64$	$30 \times 3 \times 64$
$S_L \times T_5 \times F_1$	$25 \times 1 \times 64$	$25 \times 13 \times 64$	$15 \times 13 \times 64$	$30 \times 2 \times 64$
$S_L \times 1 \times F_2$	$25 \times 1 \times 64$	$25 \times 1 \times 832$	$15 \times 1 \times 832$	$30 \times 1 \times 128$
$S_L \times F_2$	25×64	25×832	15×832	30×128
$S_L \times (2 \times N_L)$	$25 \times (2 \times 200)$	$25 \times (2 \times 200)$	$15 \times (2 \times 200)$	$30 \times (2 \times 200)$
$1 \times S_L \times 2 \times N_L$	1×10000	1×10000	1×6000	1×12000
$1 \times N_A$	1×52	1×49 /1×52	1×26	1×6

Tabela 5 – Hiperparâmetros ajustados para a EMGHandNet.

Camada	Parâmetro	Valor
Hiperparâmetros de convolução	Inicializador:	he_normal
	Passos:	2
	Regularizador:	10^{-4}
Normalização de lote	ε:	10^{-6}
	Momento:	0.95
Tamanho do lote		16
Taxa de aprendizado		$l1 = 10^{-3}$
Otimizador	Adam β_1, β_2:	0.9, 0.999
Ativação		Tanh & Relu
Dropout		0.2093
Nº de épocas		200
Bi-LSTM	Células:	200
Versão TensorFlow		2.2.0

2. MsCNN: arquitetura CNN de múltiplos fluxos de Wei et al. [28].
3. EvCNN: CNN evoluída proposta por Olsson et al. [29].
4. CNNLM: arquitetura CNN-LSTM combinada de Chen et al. [40].
5. Características de energia: classificador KNN com características baseadas em energia, proposto por Karnam et al. [23].

Especificamente, esses modelos são analisados nos dois esquemas a seguir:

- Análise por participante: nesse esquema, a EMGHandNet é treinada e testada com dados de cada indivíduo. Calcula-se a acurácia média de classificação entre os participantes.
- Análise de dados agregados: nesse esquema, a EMGHandNet é treinada e testada com dados reunidos de todos os participantes disponíveis, com a divisão descrita na etapa de pré-processamento. A acurácia média é calculada segundo (7).

Para validar a EMGHandNet, realizam-se as seguintes análises: (1) efeito dos formatos de entrada; (2) comparação entre camadas RNN; (3) métodos de pré-processamento; (4) curvas de perda dos diferentes conjuntos; (5) comparação com modelos do estado da arte; e (6) complexidade de tempo e espaço. Para uma comparação justa, usamos a mesma configuração de dados e os mesmos métodos de preparação do formato de entrada para a EMGHandNet e os demais modelos.

5.1. Papel dos formatos de entrada

A EMGHandNet também é analisada com diferentes formatos de dados de entrada, como mostra a Fig. 5 para os cinco conjuntos. Observa-se que, em alguns conjuntos, um formato de entrada com segmentos temporais de 200 ms (NinaPro DB1: T_S = 20 amostras; NinaPro DB2, DB4 e BioPatRec DB2: T_S = 400 amostras) ou de 50 ms (UCI Gesture: T_S = 50 amostras) apresenta desempenho superior ao de outros segmentos temporais. Para o BioPatRec, a maior acurácia, 83,9%, é obtida com formato [15, 400], correspondente a segmentos de 200 ms. Isso sugere que o desempenho varia conforme o formato de entrada e atinge acurácia média ideal para um formato específico.
Por fim, no UCI Gesture, um segmento de 0,05 s extraído de ensaios de 3 s melhora a classificação. Segmentos semelhantes de 0,2 s produziram melhores resultados nos outros quatro conjuntos, exceto no UCI Gesture. Portanto, escolher um segmento temporal adequado é importante para capturar relações temporais. O segmento ideal depende de fatores como frequência de amostragem (N_s), duração da atividade (T) e número de amostras na subsequência (T_S). O treinamento e o teste dos cinco conjuntos são realizados independentemente, e não se observa relação linear direta entre o número de amostras por ensaio (N_T) e o segmento temporal ideal.

5.2. Análise de desempenho com camadas RNN

O desempenho da EMGHandNet também é analisado variando o número de camadas Bi-LSTM empilhadas, com resultados na Fig. 6. Observa-se que o modelo com quatro camadas convolucionais e duas Bi-LSTM supera configurações com quatro camadas convolucionais e outros números de camadas Bi-LSTM.

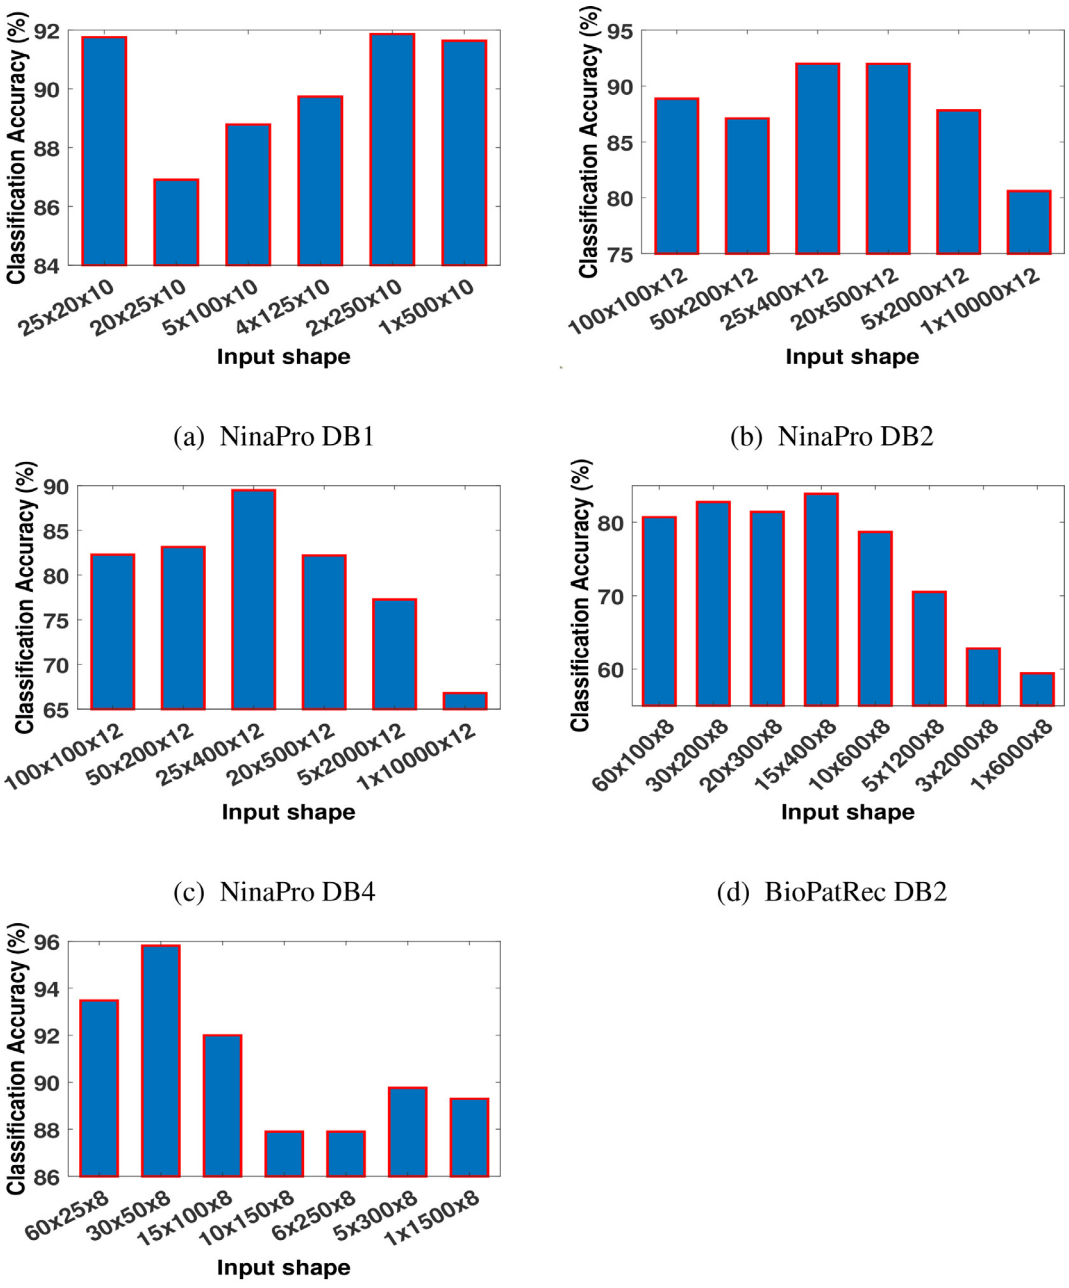


Fig. 5 – Análise de desempenho no esquema de dados agregados para diferentes formatos de entrada dos conjuntos NinaPro DB1, NinaPro DB2, NinaPro DB4, BioPatRec DB2 e UCI Gesture. Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; para UCI Gesture, T_S = 50 (segmento de 50 ms).

A configuração sem Bi-LSTM corresponde à rede com apenas quatro camadas convolucionais. Essa análise mostra que o modelo com Bi-LSTM tem melhor desempenho do que o modelo sem Bi-LSTM (somente convoluções). Para a EMGHandNet, isso também justifica o uso de duas camadas Bi-LSTM após a CNN.

O modelo proposto é ainda analisado com diferentes tipos de camadas RNN, como LSTM, unidade recorrente com portas (GRU), GRU bidirecional (Bi-GRU), RNN e RNN bidirecional (Bi-RNN), no conjunto NinaPro DB1.

Os resultados de acurácia da classificação aparecem na Fig. 7. Eles indicam que a Bi-LSTM é mais adequada à estrutura proposta, pois apresenta desempenho superior aos demais tipos de camadas RNN. A Bi-LSTM captura melhor as relações temporais de longo prazo porque aprende características temporais nos sentidos direto e inverso.

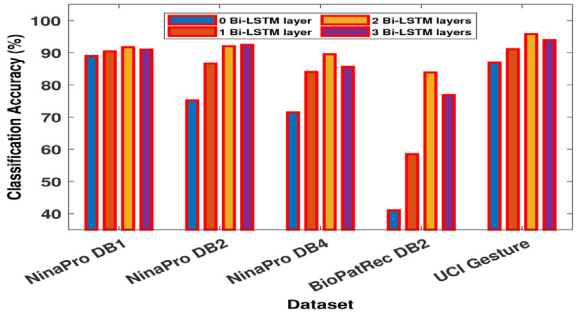


Fig. 6 – Análise do desempenho em função do número de camadas Bi-LSTM no modelo EMGHandNet proposto, para todos os conjuntos (dados agregados). Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento de 50 ms).

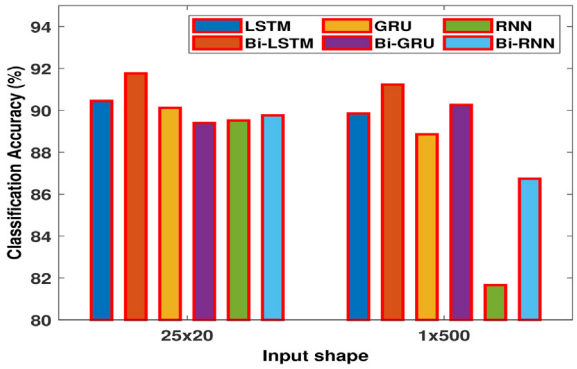


Fig. 7 – Análise de desempenho no NinaPro DB1 usando diferentes camadas recorrentes no modelo proposto: LSTM, Bi-LSTM, GRU, Bi-GRU, RNN e Bi-RNN.

5.3. Análise dos métodos de pré-processamento

O papel do pré-processamento na melhora da classificação é analisado pelos experimentos da Tabela 6. Em um deles, o método de pré-processamento da EvCNN [29] é substituído por nossa abordagem. Compara-se essa combinação à aplicação do pré-processamento da EvCNN seguida da EMGHandNet. A EMGHandNet com nossos dados pré-processados apresenta maior acurácia que as outras combinações. Essa análise mostra que o pré-processamento usado neste trabalho é mais adequado à classificação de atividades da mão por sEMG do que o pré-processamento e a arquitetura de [29]. Outros experimentos comparam a EMGHandNet com e sem pré-processamento. No BioPatRec DB2, observa-se melhora de 17,69% na acurácia em relação à ausência de pré-processamento. Da mesma forma, no NinaPro DB4, a melhora é de 10,58%. Nos demais conjuntos, a melhora é de pelo menos 3%. Assim, o pré-processamento aumenta o desempenho do modelo em comparação ao uso direto dos dados.

5.4. Curvas de perda de cada conjunto de dados

A Fig. 8 mostra as curvas de perda da EMGHandNet para os cinco conjuntos. Os formatos de entrada escolhidos são: NinaPro DB1, 25 × 20 × 10; NinaPro DB2 e DB4, 25 × 400 × 12; BioPatRec DB2, 15 × 400 × 8; e UCI Gesture, 30 × 50 × 8. A resposta da EMGHandNet se estabiliza após 70 épocas em cada conjunto.

5.5. Comparação de desempenho

O desempenho da EMGHandNet é comparado ao de MsCNN, EvCNN e CNNLM, cujos resultados foram reproduzidos neste trabalho, e ao de outros modelos reportados na literatura (Tabelas 7 e 8).
Na análise por participante (Tabela 7), a EMGHandNet apresenta acurácia média de teste superior aos métodos do estado da arte nos conjuntos NinaPro. No NinaPro DB1, a acurácia média é 95,77%, melhora de 7,57 pontos percentuais em relação aos 88,2% da CNN de múltiplas vistas [57]. No NinaPro DB2, sua acurácia de 95,9% representa melhora de 12,2 pontos em relação aos 83,7% do mesmo modelo [57]. A EMGHandNet também supera em 8,73 pontos a CNNLM reproduzida [40]. No NinaPro DB4, a acurácia média de 91,65% supera o modelo Attention sEMG [58] em 18,65 pontos. No UCI Gesture, há pequena melhora de 1,33 ponto sobre uma arquitetura neural profunda [59], chegando a 98,33%. Como o BioPatRec DB2 é usado na literatura sem aumento de dados, o resultado da EMGHandNet (91,29%) aproxima-se do estado da arte.

Tabela 6 – Análise de desempenho, em acurácia (%), de diferentes técnicas de pré-processamento com diversas arquiteturas, no esquema de dados agregados. Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento de 50 ms).

Conjunto / Metodologia	NinaPro DB1	NinaPro DB2	NinaPro DB4	BioPatRec DB2	UCI Gesture
Pré-proc. Olsson - EvCNN [29]	81.57	66.64	13	77.71	54.41
Pré-proc. Olsson - EMGHandNet	86.98	81.11	21.6	67.8	91.16
Pré-proc. proposto - EvCNN [29]	84.54	60.52	38	52.71	77.2
Pré-proc. proposto - EMGHandNet	**91.76**	**92.01**	**89.5**	**83.9**	**93.48**
Sem pré-proc. - EMGHandNet	89.5	91.62	78.92	66.21	93.02

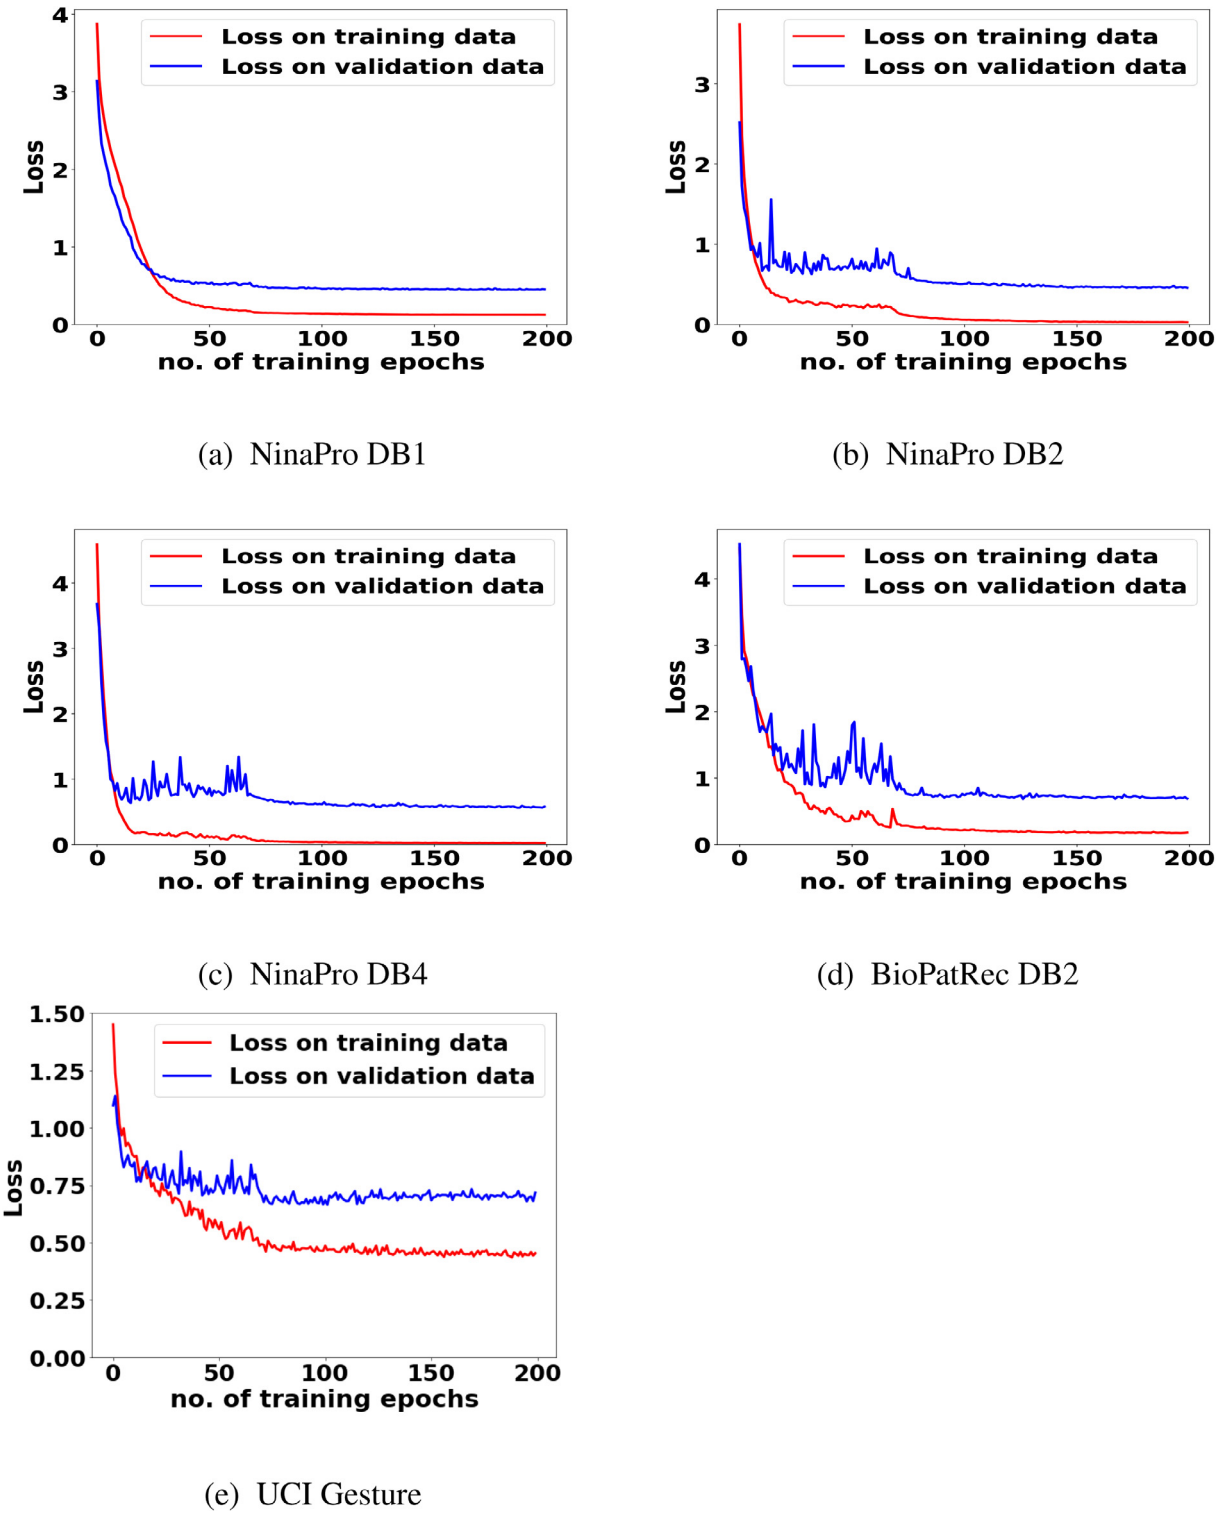


Fig. 8 – Curvas de perda observadas durante o treinamento da EMGHandNet nos conjuntos NinaPro DB1, NinaPro DB2, NinaPro DB4, BioPatRec DB2 e UCI Gesture (dados agregados). Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento de 50 ms).

No esquema agregado (Tabela 8), a acurácia da EMGHandNet também é superior à dos modelos existentes para os conjuntos NinaPro. Especificamente, no NinaPro DB1, a EMGHandNet alcançou 91,76%, resultado pelo menos 3,56 pontos superior aos 88,2% da CNN de múltiplas vistas [57]. No NinaPro DB2, observa-se acurácia de 92,01% com a EMGHandNet, melhora de 8,31 pontos em relação aos

Tabela 7 – Acurácia de classificação (%) com diferentes arquiteturas, em análise por participante. * indica resultados reproduzidos. Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento de 50 ms).

Conjunto / Arquitetura	NinaPro DB1	NinaPro DB2	NinaPro DB4	BioPatRec DB2	UCI Gesture
RMS, MAV, and DASDV by yang et al. [55] (por participante)	91.35	-	-	-	-
Imagem multicaracterísticas sEMG by Cheng et al. [56]	82.54	-	-	-	-
MsCNN [28] (por participante	85	-	-	-	-
MsCNN[28] (por participante)*	74.25	50.99	34.1	66.18	95.58
EvCNN [29] (por participante	81.4	71.6	-	91.4	-
EvCNN [29] (por participante)*	68.06	80.54	22.3	84.19	45.55
CNN-RNN by Hu et al. [36]	87	82.2	-	94.1	-
Multi-View CNN by Wei et al. [57]	88.2	83.7	58	94.0	-
sEMG com atenção by Josephs et al. [58]	-	-	73	-	-
Rede neural profunda by Potekhin et al. [59]	-	-	-	-	97
CNNLM [40] (por participante)*	92.99	87.17	87.37	89.17	86.51
EMGHandNet (por participante)	**95.77**	**95.9**	**91.65**	**91.29**	**98.33**

Tabela 8 – Acurácia de classificação (%) com diferentes arquiteturas, no esquema de dados agregados. * indica resultados reproduzidos. Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento de 50 ms).

Conjunto / Arquitetura	NinaPro DB1	NinaPro DB2	NinaPro DB4	BioPatRec DB2	UCI Gesture
Benchmark classifier with características manuais [26] (agregado)	75.3	75.3	-	-	-
CNN by Atzori et al. [25] (agregado)	66.6	60.3	-	-	-
LDA by Nazemi et al. [60]	84.23	-	-	-	-
LS-SVM by Nazemi et al. [60]	85.19	-	-	-	-
Random Forest by Rubio et al. [61]	-	-	-	-	95.39
Características de energia [23] (agregado)	87.07	90.61*	60.67*	89.36*	93.98*
MsCNN [28] (agregado)*	60	31.41	33.9	62.4	89.5
EvCNN [29] (agregado)*	81.57	66.64	13	77.71	54.41
CNN-RNN by Hu et al. [36]	87	82.2	-	94.1	-
Multi-View CNN by Wei et al. [57]	88.2	83.7	58	94.0	-
sEMG com atenção by Josephs et al. [58]	-	-	73	-	-
CNNLM [40] (agregado)*	79.26	78.71	83.92	71.65	86.51
EMGHandNet (agregado)	**91.76**	**92.01**	**89.5**	**83.9**	**93.48**

Tabela 9 – Estatísticas do teste de McNemar para características de energia [23] e EMGHandNet no NinaPro DB2. Comparação de desempenho baseada nas proporções corretas.

		Energy Features [23]		
		Correct	Incorrect	Total
EMGHandNet	Correct	$f_{cc} = 3350$	$f_{ic} = 200$	3550
	Incorrect	$f_{ci} = 255$	$f_{ii} = 113$	368
	Total	3605	313	3918

83,7% da CNN de múltiplas vistas [57], além de melhora de 1,4 ponto sobre as características de energia [23]. No NinaPro DB4, a acurácia de 89,5% representa aumento de 5,58 pontos em relação aos 83,92% da CNNLM [40]. No UCI Gesture, 93,48% representa melhora de 3,98 pontos em relação aos 89,5% da MsCNN [28]. Por fim, no BioPatRec, a EMGHandNet apresenta melhora de 6,19 pontos em relação à acurácia da EvCNN [29]. A EMGHandNet supera classificadores de aprendizado de máquina como [26,23]. Entre os métodos existentes para os cinco conjuntos, CNNLM [40] e características de energia [23] chegam mais perto da acurácia da EMGHandNet. Além disso, em quatro conjuntos, exceto UCI Gesture, a MsCNN [28] apresenta o pior desempenho entre os métodos concorrentes.

O teste de McNemar [62] é aplicado para analisar a significância estatística da melhora observada. Os termos da Tabela 9 são definidos assim: f_cc corresponde ao número de padrões classificados corretamente pelos dois classificadores; f_ci, aos casos em que a EMGHandNet acerta e o classificador de referência erra; f_ic, ao inverso; e f_ii, aos casos em que ambos erram. A estatística qui-quadrado calculada [62] é 6,64 > 3,84 (limiar para um grau de liberdade). Portanto, a melhora é significativa com 95% de confiança. Para NinaPro DB1, o valor qui-quadrado em relação às características de energia [23] é 47,2; para NinaPro DB4, em relação à CNNLM [40], é 10,07. Para UCI Gesture, o valor qui-quadrado em relação às características de energia [23] é

0,529, indicando que os dois classificadores apresentam resultados semelhantes.

5.6. Análise da complexidade temporal e espacial

A complexidade temporal e espacial dos métodos de aprendizado de máquina é calculada com base na análise de [29]. A complexidade temporal das camadas Conv 1D, Bi-LSTM e totalmente conectadas (FC) é determinada pela quantidade de operações de ponto flutuante por segundo (FLOPS), conforme a Tabela 10. A complexidade temporal do UCI Gesture pode ser calculada de forma semelhante à dos quatro primeiros conjuntos. O tempo total de treinamento para NinaPro DB1, NinaPro DB2, NinaPro DB4, BioPatRec DB2 e UCI Gesture é, respectivamente, de 48 min, 48,3 min, 16 min, 6,6 min e 6,6 min. A complexidade espacial de Conv 1D, Bi-LSTM, FC e normalização em lote (BN) é dada por 4HC [29], com base na dimensão da saída H × C, conforme a Tabela 11. Memória adicional é alocada de acordo com o número de parâmetros de aprendizado (pesos e vieses).
A complexidade temporal e espacial da Bi-LSTM é igual [43]. A complexidade espacial das camadas Conv 1D [63], FC e BN é calculada teoricamente considerando um sistema operacional de 32 bits.

A complexidade computacional depende do número de parâmetros treináveis. Com base nisso, as diferentes arquiteturas são comparadas na Tabela 12. Na maioria dos conjuntos, a complexidade da EMGHandNet é maior que a da EvCNN e CNNLM, mas menor que a da MsCNN.

5.7. Discussão

O desempenho da EMGHandNet proposta melhorou pelas seguintes razões:

- A arquitetura híbrida CNN e Bi-LSTM consegue extrair características entre canais e temporais. A convolução 1D codifica informações entre canais e temporais de curto prazo, enquanto a Bi-LSTM codifica informações temporais de longo prazo, nos sentidos direto e inverso.
- Os dados de um ensaio completo são fornecidos ao modelo, ao contrário dos dados segmentados usados em métodos existentes. Considerar o ensaio inteiro como um padrão de entrada, em vez de um único segmento, fornece

Tabela 10 – Complexidade temporal das camadas da rede (n = número de filtros, v = passo vertical, y = altura do núcleo, N = número de padrões, N_e = número de épocas e N_A = número de atividades).

Nome da camada	Formato da entrada	Valores teóricos das camadas (FLOPS)	Valores teóricos for NinaPro DB1 (FLOPS)	Valores teóricos for NinaPro DB2 and NinaPro DB4 (FLOPS)	Valores teóricos for BioPatRec DB2 (FLOPS)
Conv1d 64@9	$T_S \times N_C$	$(T_S/v)n(2yN_C+1)$	115840	2777600	185600
Conv1d 64@5	$T_2 \times F_1$	$(T_2/v)n(2yF_1+1)$	41024	1989664	1989664
Conv1d 64@5	$T_3 \times F_1$	$(T_3/v)n(2yF_1+1)$	20512	1005088	1005088
Conv1d 64@3	$T_4 \times F_1$	$(T_4/v)n(2yF_1+1)$	12320	308000	308000
$Bi-LSTM1$	$S_L \times F_2$	$2 \times 4 \times (F_2+N_L+1)N_L$	424000	1652800	1652800
$Bi-LSTM2$	$S_L \times 2 \times N_L$	$2 \times 4 \times (2N_L+N_L+1)N_L$	1281600	1281600	1281600
FC1	$1 \times S_L \times 2 \times N_L$	$S_L \times 2 \times N_L \times 512$	10000×512	10000×512	6000×512
FC2	1×512	$512 \times N_A$	512×52	$512 \times 49/512 \times 52$	512×26
Total	–	–	5760320	14159840/14161376	6743264
$O(f)$	–	$Total \times N \times N_e$	1.6×10^{13}	$3.3 \times 10^{13}/8.8 \times 10^{12}$	1.7×10^{12}

Tabela 11 – Complexidade espacial das camadas da rede (n = número de filtros, v = passo vertical, y = altura do núcleo e N_A = número de atividades).

Nome da camada	Formato da entrada	Formato da saída	Based on Formato da saída (bytes)	Baseado em parâmetros treináveis (bytes)
Conv1d 64@9	$T_S \times N_C$	$T_1 \times F_1$	$4T_1F_1$	$4n(yN_C+1)$
Conv1d 64@5	$T_2 \times F_1$	$T_3 \times F_1$	$4T_3F_1$	$4n(yF_1+1)$
Conv1d 64@5	$T_3 \times F_1$	$T_4 \times F_1$	$4T_4F_1$	$4n(yF_1+1)$
Conv1d 64@3	$T_4 \times F_1$	$T_5 \times F_1$	$4T_5F_1$	$4n(yF_1+1)$
$Bi-LSTM1$	$S_L \times F_2$	$S_L \times (2 \times N_L)$	$4 \times 2S_LN_L$	$4 \times 2 \times 4 \times (F_2+N_L+1)N_L$
$Bi-LSTM2$	$S_L \times (2 \times N_L)$	$S_L \times (2 \times N_L)$	$4 \times 2S_LN_L$	$4 \times 2 \times 4 \times (2N_L+N_L+1)N_L$
FC1	$1 \times S_L \times 2 \times N_L$	1×512	4×512	$4 \times 512(S_L \times 2 \times N_L+1)$
FC2	1×512	$1 \times N_A$	$4 \times N_A$	$4 \times N_A(512+1)$
BN1	$T_1 \times F_1$	$T_1 \times F_1$	$4T_1F_1$	$16 \times F_1$
BN2	$T_3 \times F_1$	$T_3 \times F_1$	$4T_3F_1$	$16 \times F_1$
BN3	$T_4 \times F_1$	$T_4 \times F_1$	$4T_4F_1$	$16 \times F_1$
BN4	$T_5 \times F_1$	$T_5 \times F_1$	$4T_5F_1$	$16 \times F_1$
BN5	1×512	1×512	4×512	16×512

Tabela 12 – Comparação da complexidade computacional, com base nos parâmetros treináveis de diferentes arquiteturas, no esquema de dados agregados. Para NinaPro DB1, T_S = 20; para NinaPro DB2, DB4 e BioPatRec DB2, T_S = 400; e para UCI Gesture, T_S = 50 (segmento de 50 ms).

Parâmetros treináveis / Metodologia	NinaPro DB1	NinaPro DB2	NinaPro DB4	BioPatRec DB2	UCI Gesture
MsCNN [28]	8.69×10^6	3.12×10^6	1.97×10^8	9.90×10^7	6.61×10^7
EvCNN [29]	3.77×10^5	1.31×10^7	2.80×10^6	2.92×10^6	1.66×10^6
CNNLM [40]	1.52×10^5	5.41×10^5	5.42×10^5	4.15×10^5	3.06×10^5
EMGHandNet	6.59×10^6	7.82×10^6	7.82×10^6	5.76×10^6	7.69×10^6

informações sequenciais melhores para o modelo, pois não sabemos em qual segmento temporal o participante executou a atividade durante o ensaio.

Observa-se que a análise por participante apresenta desempenho superior ao esquema de dados agregados, pois o modelo compreende melhor as ações da mão devido à menor covariância intraparticipante dos sinais, em contraste com a maior covariância entre participantes no segundo esquema. Observa-se uma tendência ou correlação entre a duração do segmento classificado e o desempenho. Por exemplo, segmentos de 0,2 s apresentaram melhores resultados em NinaPro DB1, NinaPro DB2, NinaPro DB4 e BioPatRec DB2; no UCI Gesture, o melhor foi 0,05 s. Conclui-se que o desempenho depende do formato dos dados fornecidos à CNN. Algumas limitações do modelo proposto são: (a) pode ser necessário desenvolver novas melhorias para elevar o desempenho no BioPatRec DB2; (b) cada conjunto exige treinamento e teste separados. Para reduzir o retreinamento, pode-se explorar o aprendizado por transferência.

6. Conclusão e perspectivas futuras

6.1. Conclusão

Neste artigo, propusemos uma arquitetura híbrida CNN e Bi-LSTM para classificar atividades da mão humana por meio de sinais sEMG. A EMGHandNet foi analisada em cinco conjuntos sEMG de referência. Ela supera modelos do estado da arte em acurácia média de classificação para NinaPro DB1, DB2 e DB4, com melhorias de pelo menos 4% e de até 18,65%. Também se observa desempenho superior no esquema de dados agregados. Verifica-se ainda que o pré-processamento empregado neste trabalho é melhor que os métodos existentes para esse problema. Além disso, o desempenho da EMGHandNet pode ser ajustado pelo formato dos dados de entrada fornecidos ao wrapper de distribuição temporal. Por fim, a Bi-LSTM com duas camadas mostrou-se uma escolha melhor que outros tipos de RNN.

6.2. Perspectivas futuras

Como os sinais sEMG são considerados apenas no domínio do tempo, existe a possibilidade de melhorar o desempenho convertendo-os para o domínio wavelet ou para o domínio da decomposição em modos empíricos (EMD), antes do processamento pelos modelos de aprendizado profundo. O modelo também pode ser implementado em hardware para examinar dificuldades práticas. Entre elas estão a latência e a portabilidade. A latência para testar uma amostra varia de 1,8 µs, no melhor caso, a 518 µs, no pior, fator importante para implementações em tempo real. Pretendemos construir um conjunto de sinais sEMG da população indiana para analisar variações geográficas entre conjuntos. Finalmente, o modelo pode ser aprimorado para aprender sinais de movimentos altamente dinâmicos e rápidos, como os praticados em esportes.

Declaração de conflitos de interesse

Os autores declaram não possuir interesses financeiros conflitantes nem relações pessoais conhecidas que possam ter influenciado o trabalho relatado neste artigo.

Agradecimento

Esta pesquisa foi financiada pelo SERB, Governo da Índia, por meio da concessão para o projeto CRG/2019/003801.

REFERÊNCIAS

[1] Guo W, Yao P, Sheng X, Zhang D, Zhu X. An enhanced human-computer interface based on simultaneous sEMG and NIRS for prostheses control. In: 2014 IEEE International Conference on Information and Automation (ICIA). p. 204–7.
[2] Fan Y, Yin Y. Active and progressive exoskeleton rehabilitation using multisource information fusion from EMG and force-position EPP. IEEE Trans Biomed Eng. 2013;60 (12):3314–21.
[3] Li Y, Chen X, Zhang X, Wang K, Wang ZJ. A sign-component-based framework for chinese sign language recognition using accelerometer and sEMG data. IEEE Trans Biomed Eng 2012;59 (10):2695–704.
[4] Cheng J, Chen X, Lu Z, Wang K, Shen M. Key-press gestures recognition and interaction based on sEMG signals. In: International Conference on Multimodal Interfaces and the Workshop on Machine Learning for Multimodal Interaction. ICMI-MLMI '10. New York, NY, USA: Association for Computing Machinery; 2010. p. 1–4.
[5] Qi W, Su H, Aliverti A. A smartphone-based adaptive recognition and real-time monitoring system for human activities. IEEE Trans Hum Mach Syst 2020;50(5):414–23.
[6] Wen R, Tay W, Nguyen BP, Chng CB, Chui CK. Hand gesture guided robot-assisted surgery based on a direct augmented

reality interface. Comput Methods Programs Biomed 2014;116 (2):68–80.
[7] Wachs JP, Kölsch M, Stern H, Edan Y. Vision-based hand-gesture applications. Commun ACM 2011;54(2):60–71.
[8] Lu Z, Chen X, Li Q, Zhang X, Zhou P. A hand gesture recognition framework and wearable gesture-based interaction prototype for mobile devices. IEEE Trans Hum Mach Syst 2014;44(2):293–9.
[9] Lu Z, Tong K, Shin H, Li S, Zhou P. Advanced myoelectric control for robotic hand-assisted training: outcome from a stroke patient. Front Neurol 2017;8:107.
[10] Li Z, Xia Y, Su C. Intelligent networked teleoperation control. Springer; 2015.
[11] Su H, Qi W, Li Z, Chen Z, Ferrigno G, De Momi E. Deep neural network approach in EMG-based force estimation for human-robot interaction. IEEE Trans Artif Intell 2021;2 (5):404–12.
[12] Schabron B, Desai J, Yihun Y. Wheelchair-mounted upper limb robotic exoskeleton with adaptive controller for activities of daily living. Sensors 2021;21(17).
[13] Kim K, Park S, Lim T, Lee SJ. Upper-limb electromyogram classification of reaching-to-grasping tasks based on convolutional neural networks for control of a prosthetic hand. Front Neurosci 2021;15.
[14] Su H, Ovur SE, Zhou X, Qi W, Ferrigno G, De Momi E. Depth vision guided hand gesture recognition using electromyographic signals. Adv Robot 2020;34(15):985–97.
[15] Phinyomark A, Scheme E. An investigation of temporally inspired time domain features for electromyographic pattern recognition. In: 2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC); 2018. p. 5236–5240.
[16] Phinyomark A, Phukpattaranont P, Limsakul C. Feature reduction and selection for EMG signal classification. Expert Syst Appl 2012;39(8):7420–31.
[17] Shenoy P, Miller KJ, Crawford B, Rao RPN. Online electromyographic control of a robotic prosthesis. IEEE Trans Biomed Eng 2008;55(3):1128–35.
[18] Al-Timemy AH, Khushaba RN, Bugmann G, Escudero J. Improving the performance against force variation of EMG controlled multifunctional upper-limb prostheses for transradial amputees. IEEE Trans Neural Syst Rehabil Eng 2016;24(6):650–61.
[19] Shi WT, Lyu ZJ, Tang ST, Chia TL, Yang CY. A bionic hand controlled by hand gesture recognition based on surface EMG signals: A preliminary study. Biocybern Biomed Eng 2018;38 (1):126–35.
[20] Waris A, Niazi IK, Jamil M, Englehart K, Jensen W, Kamavuako EN. Multiday evaluation of techniques for EMG-based classification of hand motions. IEEE J Biomed Health Inform 2019;23(4):1526–34.
[21] Tuncer T, Dogan S, Subasi A. Surface EMG signal classification using ternary pattern and discrete wavelet transform based feature extraction for hand movement recognition. Biomed Signal Process Control 2020;58 101872.
[22] Fatimah B, Singh P, Singhal A, Pachori RB. Hand movement recognition from sEMG signals using fourier decomposition method. Biocybern Biomed Eng 2021;41(2):690–703.
[23] Karnam NK, Turlapaty AC, Dubey SR, Gokaraju B. Classification of sEMG signals of hand gestures based on energy features. Biomed Signal Process Control 2021;70 102948.
[24] LeCun Y, Bengio Y, Hinton G. Deep learning. Nature 2015;521 (7553):436–44.
[25] Atzori M, Cognolato M, Müller H. Deep learning with convolutional neural networks applied to electromyography data: A resource for the classification of movements for prosthetic hands. Front Neurorobot 2016;10:9.
[26] Atzori M, Gijsberts A, Castellini C, Caputo B, Hager AGM, Elsig S, et al. Electromyography data for non-invasive naturally-controlled robotic hand prostheses. Sci Data 2014;1(1) 140053.
[27] Geng W, Du Y, Jin W, Wei W, Hu Y, Li J. Gesture recognition by instantaneous surface EMG images. Sci Rep 2016;6(1):36571.
[28] Wei W, Wong Y, Du Y, Hu Y, Kankanhalli M, Geng W. A multi-stream convolutional neural network for sEMG-based gesture recognition in muscle-computer interface. Pattern Recognit Lett 2019;119:131–8.
[29] Olsson AE, Björkman A, Antfolk C. Automatic discovery of resource-restricted convolutional neural network topologies for myoelectric pattern recognition. Comput Biol Med 2020;120 103723.
[30] Côté-Allard U, Fall CL, Drouin A, Campeau-Lecours A, Gosselin C, Glette K, et al. Deep learning for electromyographic hand gesture signal classification using transfer learning. IEEE Trans Neural Syst Rehabil Eng 2019;27 (4):760–71.
[31] Qi S, Wu X, Chen WH, Liu J, Zhang J, Wang J. sEMG-based recognition of composite motion with convolutional neural network. Sens Actuators A Phys 2020;311 112046.
[32] Betthauser JL, Krall JT, Bannowsky SG, Lévay G, Kaliki RR, Fifer MS, et al. Stable responsive EMG sequence prediction and adaptive reinforcement with temporal convolutional networks. IEEE Trans Biomed Eng 2020;67(6):1707–17.
[33] Gautam A, Panwar M, Wankhede A, Arjunan SP, Naik GR, Acharyya A, et al. Locomo-Net: A low-complex deep learning framework for sEMG-based hand movement recognition for prosthetic control. IEEE J Transl Eng Health Med 2020;8:1–12.
[34] Koch P, Dreier M, Maass M, Phan H, Mertins A. RNN with stacked architecture for sEMG based sequence-to-sequence hand gesture recognition. In: 2020 28th European Signal Processing Conference (EUSIPCO). p. 1600–4.
[35] Ketykó I, Kovács F, Varga KZ. Domain adaptation for sEMG-based gesture recognition with recurrent neural networks. In: 2019 International Joint Conference on Neural Networks (IJCNN). p. 1–7.
[36] Hu Y, Wong Y, Wei W, Du Y, Kankanhalli M, Geng W. A novel attention-based hybrid CNN-RNN architecture for sEMG-based gesture recognition. PLoS One 2018;13(10):1–18.
[37] Wang Y, Wu Q, Dey N, Fong S, Ashour AS. Deep back propagation–long short-term memory network based upper-limb sEMG signal classification for automated rehabilitation. Biocybern Biomed Eng 2020;40(3):987–1001.
[38] Donahue J, Anne Hendricks L, Guadarrama S, Rohrbach M, Venugopalan S, Saenko K, et al. Long-term recurrent convolutional networks for visual recognition and description. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). p. 2625–34.
[39] Bao T, Zaidi SAR, Xie S, Yang P, Zhang ZQ. A CNN-LSTM hybrid model for wrist kinematics estimation using surface electromyography. IEEE Trans Instrum Meas 2021;70:1–9.
[40] Chen X, Li Y, Hu R, Zhang X, Chen X. Hand gesture recognition based on surface electromyography using convolutional neural network with transfer learning method. IEEE J Biomed Health Inform 2021;25(4):1292–304.
[41] Krizhevsky A, Sutskever I, Hinton GE. Imagenet classification with deep convolutional neural networks. Adv Neural Inf Process Syst 2012;25:1097–105.
[42] Bengio Y, Simard P, Frasconi P. Learning long-term dependencies with gradient descent is difficult. IEEE Trans Neural Netw 1994;5(2):157–66.
[43] Hochreiter S, Schmidhuber J. Long short-term memory. Neural Comput 1997;9(8):1735–80.
[44] Scheme E, Englehart K. On the robustness of EMG features for pattern recognition based myoelectric control; A multi-dataset comparison. In: 2014 36th Annual International

Conference of the IEEE Engineering in Medicine and Biology Society; 2014. p. 650–653.
[45] Scheme EJ, Hudgins BS, Englehart KB. Confidence-based rejection for improved pattern recognition myoelectric control. IEEE Trans Biomed Eng 2013;60(6):1563–70.
[46] Amsüss S, Goebel PM, Jiang N, Graimann B, Paredes L, Farina D. Self-correcting pattern recognition system of surface EMG signals for upper limb prosthesis control. IEEE Trans Biomed Eng 2014;61(4):1167–76.
[47] Lu Z, Tong K, Zhang X, Li S, Zhou P. Myoelectric pattern recognition for controlling a robotic hand: A feasibility study in stroke. IEEE Trans Biomed Eng 2019;66(2):365–72.
[48] Criswell E. Cram's introduction to surface electromyography. Burlington: Jones & Bartlett Publishers; 2010.
[49] Reifinger S, Wallhoff F, Ablassmeier M, Poitschke T, Rigoll G. Static and dynamic hand-gesture recognition for augmented reality applications. In: International Conference on Human-Computer Interaction. Springer; 2007. p. 728–37.
[50] Leonardis D, Barsotti M, Loconsole C, Solazzi M, Troncossi M, Mazzotti C, et al. An EMG-controlled robotic hand exoskeleton for bilateral rehabilitation. IEEE Trans Haptics 2015;8(2):140–51.
[51] Dunai L, Novak M, García Espert C. Human hand anatomy-based prosthetic hand. Sensors 2021;21(1):137.
[52] Pizzolato S, Tagliapietra L, Cognolato M, Reggiani M, Müller H, Atzori M. Comparison of six electromyography acquisition setups on hand movement classification tasks. PLoS One 2017;12(10):1–17.
[53] Ortiz-Catalan M, Brånemark R, Håkansson B. BioPatRec: A modular research platform for the control of artificial limbs based on pattern recognition algorithms. Source Code Biol Med 2013;8(1):11.
[54] Lobov S, Krilova N, Kastalskiy I, Kazantsev V, Makarov VA. Latent factors limiting the performance of sEMG-interfaces. Sensors 2018;18(4):1122.
[55] Yang K, Xu M, Yang X, Yang R, Chen Y. A novel EMG-based hand gesture recognition framework based on multivariate variational mode decomposition. Sensors 2021;21(21):7002.
[56] Cheng Y, Li G, Yu M, Jiang D, Yun J, Liu Y, et al. Gesture recognition based on surface electromyography-feature image. Concurr Comput 2021;33(6) e6051.
[57] Wei W, Dai Q, Wong Y, Hu Y, Kankanhalli M, Geng W. Surface-electromyography-based gesture recognition by multi-view deep learning. IEEE Trans Biomed Eng 2019;66(10):2964–73.
[58] Josephs D, Drake C, Heroy A, Santerre J. sEMG gesture recognition with a simple model of attention. In: Alsentzer E, McDermott MBA, Falck F, Sarkar SK, Roy S, Hyland SL, editors. Proceedings of the Machine Learning for Health NeurIPS Workshop. vol. 136 of Proceedings of Machine Learning Research. PMLR. p. 126–38.
[59] Potekhin VV, Unal O. Development of machine learning models to determine hand gestures using EMG signals. Ann DAAAM Proceedings 2020;7(1).
[60] Nazemi A, Maleki A. Artificial neural network classifier in comparison with LDA and LS-SVM classifiers to recognize 52 hand postures and movements. In: 2014 4th International Conference on Computer and Knowledge Engineering (ICCKE). IEEE; 2014. p. 18–22.
[61] Rubio AM, Grisales JAA, Tabares-Soto R, Orozco-Arias S, Varón CFJ, Buriticá JIP. Identification of hand movements from electromyographic signals using machine learning; 2020.
[62] Foody GM. Thematic map comparison. Photogramm Eng Remote Sensing 2004;70(5):627–33.
[63] Dumoulin V, Visin F. A guide to convolution arithmetic for deep learning; 2018.