Seleção do melhor conjunto de características para reconhecimento de gestos da mão baseado em sEMG utilizando uma arquitetura CNN

Jorge Arturo Sandoval-Espino; Alvaro Zamudio-Lara; José Antonio Marbán-Salgado; J. Jesús Escobedo-Alatorre; Omar Palillero-Sandoval; J. Guadalupe Velásquez-Aguilar

Sensors 2022, 22, 4972 · Tradução para português brasileiro · DOI: 10.3390/s22134972

Resumo

A classificação de sinais mioelétricos de superfície (sEMG) continua sendo um grande desafio quando se considera sua implementação em uma prótese eletromecânica de mão, devido à sua natureza não linear e estocástica, bem como à grande diferença entre os modelos aplicados de forma offline e online. Neste trabalho, apresenta-se a seleção do conjunto de características que permitiu obter os melhores resultados para a classificação desse tipo de sinal.

Para comparar os resultados, foram utilizadas as bases NinaPro DB2 e DB3, com informações sobre 50 movimentos diferentes de 40 indivíduos saudáveis e 11 indivíduos amputados, respectivamente. Os sinais sEMG foram adquiridos por 12 canais em configuração bipolar. Para classificação, utilizou-se uma rede neural convolucional (CNN), comparando quatro conjuntos de características no domínio do tempo: TD1, com seis características; TD2, com dez características, incluindo autorregressão (AR); TD-PSD1, com duas características derivadas de momentos espectrais; e TD-PSD2, com cinco características relacionadas ao espectro de potência obtidas no domínio do tempo. Os conjuntos foram organizados de quatro maneiras para formar imagens de treinamento. TD-PSD2 apresentou o melhor desempenho em todos os casos. O método proposto aumentou as acurácias em 8,16% e 8,56% para DB2 e DB3 em comparação ao estado da arte então disponível.

Palavras-chave: sEMG; classificação; rede neural convolucional; reconhecimento de gestos; prótese.

1. Introdução

O uso de sEMG no reconhecimento de gestos para controle de uma prótese de mão é atualmente o método mais utilizado, por ser uma técnica não invasiva e de fácil implementação [1]. Devido à natureza estocástica, não linear e não estacionária dos sinais [2], a análise direta dos sinais mioelétricos brutos é impraticável. O procedimento típico envolve aquisição de sEMG, processamento digital, segmentação, extração de características e classificação [3]. Há diversas variáveis, como número de eletrodos, largura de banda do filtro, tamanho das janelas e, especialmente, o conjunto de características e o método de classificação.

Trabalhos recentes mostraram resultados promissores com aprendizado profundo para a análise de sinais fisiológicos [4]. As CNNs [5] apresentaram os melhores desempenhos na classificação de sEMG [6–10]. A representação do sinal como imagem admite duas abordagens. Na primeira, uma janela temporal forma uma imagem cuja altura representa os canais e cuja largura representa as amostras no tempo. Park et al. [6] obtiveram resultados superiores aos de SVM. Atzori et al. [8] aplicaram representação semelhante às bases NinaPro DB1, DB2 e DB3, comparando CNN com k-NN, SVM, Random Forest e LDA, e demonstraram resultados comparáveis mesmo com uma CNN simples.

A segunda abordagem foi proposta por Geng et al. [7], com a “imagem sEMG instantânea”, construída com uma matriz de canais de alta densidade próximos entre si. Cada canal fornece um valor de pixel, permitindo analisar padrões espaciais e temporais. Em NinaPro DB1, DB2 e CSL-HDEMG [12], os resultados confirmaram a existência de padrões suficientes para reconhecer gestos. Du et al. [9] utilizaram imagens semelhantes em NinaPro DB1, CSL-HDEMG e CapgMyo e propuseram adaptação de domínio profundo, melhorando resultados anteriores.

Antes do uso de CNNs, a classificação de gestos geralmente combinava extração de características com aprendizado de máquina [13–19] ou redes neurais artificiais [20–24]. Características no domínio do tempo (TD) são amplamente usadas pelo bom desempenho e baixo custo computacional [13]. Hu et al. [10] formaram imagens com características TD de Phinyomark [17], com largura igual ao número de características e altura igual aos canais reorganizados [25], e avaliaram CNN, CNN-RNN e CNN híbrida com atenção em NinaPro DB1, DB2, BioPatRec e CapgMyo, alcançando o melhor desempenho publicado até então.

Wei et al. [26] empregaram a mesma técnica para avaliar oito conjuntos de características TD e outros três derivados da transformada Wavelet, com CNN de múltiplas visualizações. Pancholi et al. [27], considerando a não linearidade e a não estacionariedade de sEMG, utilizaram duas características de momentos do espectro de potência no domínio do tempo (TD-PSD1) para estabilizar o sinal e reduzir o conjunto de treinamento, melhorando o desempenho em NinaPro DB1, DB2 e DB3.

Este trabalho propõe (1) utilizar cinco características derivadas de momentos espectrais no domínio do tempo, TD-PSD2, anteriormente estudadas por Khushaba et al. [28], que reduzem a variabilidade diante de alterações da posição do membro, para formar imagens cujos canais são reorganizados de modo a explorar todas as possíveis adjacências [25]; e (2) reorganizar não apenas os canais, mas também as características, buscando mais correlações entre ambos. A hipótese é que maior número de características espectrais no domínio do tempo e reorganização de canais e características melhorem o desempenho em DB2 e DB3. Os resultados apresentados foram os melhores publicados até então nas duas bases.

2. Materiais e métodos

Seguiu-se o procedimento típico de classificação de gestos com sEMG, incluindo uma etapa adicional de formação de imagens para treinar a CNN (Figura 1). Etapas: aquisição de sEMG → processamento do sinal → segmentação dos dados → extração de características → formação de imagens → classificação.

2.1. Aquisição de sEMG

2.1.1. Base de dados NinaPro

O projeto NinaPro dispõe de uma ampla base de sinais sEMG. Foram utilizadas as sub-bases DB2 e DB3 [29], adquiridas com 12 eletrodos e frequência de amostragem de 2 kHz. Oito eletrodos foram distribuídos ao redor do antebraço, na altura da junção do rádio com o úmero; dois foram colocados sobre pontos de atividade dos músculos flexores e extensores dos dedos; e outros dois, nos pontos de maior atividade do bíceps e tríceps.

A DB2 contém dados de 40 pessoas sem amputações (28 homens e 12 mulheres; 34 destros e 6 canhotos; idade 29,9 ± 3,9 anos). A DB3 contém dados de 11 pessoas com amputação transradial

(11 homens; 10 destros e 1 canhoto; idade 42,36 ± 11,96 anos). Os movimentos incluem 23 movimentos de preensão e funcionais, nove movimentos do punho, oito posturas da mão e nove padrões de força dos dedos, totalizando 49 movimentos. O repouso foi considerado uma classe adicional, resultando em 50 classes. Os gestos representam movimentos relevantes para atividades diárias, com base em taxonomia da mão, robótica e reabilitação [29].

Tabela 1. Especificações	DB2	DB3
Indivíduos sem amputação	40	0
Indivíduos amputados	0	11
Eletrodos sEMG	12 Delsys	12 Delsys
Gestos a classificar	50	50
Repetições	6	6
Frequência de amostragem	2 kHz	2 kHz

2.1.2. Protocolo de aquisição

Os participantes realizaram seis repetições de cada movimento, com cinco segundos por repetição e três segundos de repouso entre elas para evitar fadiga. A sequência não foi aleatória: foram executadas as seis repetições dos movimentos de uma categoria antes de seguir à próxima, favorecendo movimentos repetitivos quase inconscientes. Participantes sem amputação realizaram o protocolo com a mão direita; participantes amputados imaginaram repetir os movimentos da forma mais natural possível com o membro ausente.

2.2. Processamento do sinal

Antes da publicação, as bases foram sincronizadas com registros de tempo de alta resolução e foi aplicado um algoritmo de reetiquetagem [30] para alinhar os movimentos aos sinais de interesse. Os eletrodos possuem filtro passa-faixa Butterworth de 20–420 Hz [31] e foi utilizado um filtro de 50 Hz para eliminar interferência da rede elétrica. Neste trabalho, foi implementado um filtro digital passa-faixa de décima ordem, de 20–450 Hz, para remover sinais fora da faixa de interesse.

2.3. Segmentação dos dados

Os dados foram segmentados com janelas sobrepostas [32]. Para comparação com trabalhos anteriores, empregaram-se janelas de 200 ms [10,11,28], com sobreposição de 100 ms, e de 150 ms [8,27], com sobreposição de 25 ms. Ambos os tamanhos são inferiores a 300 ms, em conformidade com requisitos de resposta de sistemas de tempo real para controle de próteses eletromecânicas [32].

2.4. Extração de características

Foram comparados quatro conjuntos extraídos no domínio do tempo. TD1 [33]: EMG integrado (IEMG), variância (VAR), amplitude de Willison (WAMP), comprimento da forma de onda (WL), mudança de sinal da inclinação (SSC) e cruzamento por zero (ZC). TD2 [34]: valor absoluto médio (MAV), SSC, WL, VAR, WAMP, ZC e quatro coeficientes do modelo de autorregressão (AR). Ambos foram escolhidos pelos bons resultados de Wei et al. [26] em DB2 e DB3.

TD-PSD1 contém duas características derivadas dos momentos do espectro de potência no tempo, propostas por Pancholi et al. [27]: número de picos multiplicado pela potência do sinal (MPP) e cruzamentos por zero multiplicados pela potência (MZP). TD-PSD2 reúne cinco características de Khushaba et al. [28], que reduziram a variabilidade do erro de classificação diante de mudanças na posição do membro. Estas foram utilizadas pela primeira vez para treinar uma CNN.

As características TD-PSD2 são derivadas do teorema de Parseval, segundo o qual a soma dos quadrados de uma função se iguala à soma dos quadrados de sua transformada, considerando a normalização correspondente. X[k] denota o sinal na frequência; X*[k], seu complexo conjugado; P[k], o espectro de potência; k, o índice de frequência.

$$(1)\ \Sigma\ |x[j]|^2 = (1/N)\ \Sigma\ |X[k]\ X^*[k]| = \Sigma\ P[k]$$

A transformada de Fourier é simétrica em relação à frequência zero. Portanto, o cálculo dos momentos no domínio do tempo considera frequências positivas e negativas. O momento de ordem n é definido por:

$$(2)\ m_n = \Sigma\ k^n\ P[k]$$

Momentos ímpares podem ser considerados nulos para a distribuição simétrica. Pelo teorema de Parseval, o momento de ordem zero indica potência total; os momentos de ordem superior decorrem da propriedade de diferenciação temporal da transformada de Fourier.

$$(3)\ m_0 = \Sigma\ P[k] = \Sigma\ |x[j]|^2$$

$$(4)\ F[\Delta^n x[j]] = k^n\ X[k]$$

$$(5)\ m_2 = \Sigma\ k^2\ P[k] = \Sigma\ (\Delta x[j])^2$$

$$(6)\ m_4 = \Sigma\ k^4\ P[k] = \Sigma\ (\Delta^2 x[j])^2$$

As cinco características TD-PSD2 são derivadas de m_0, m_2 e m_4 (Tabela 2). Como em [28], foram escalonadas logaritmicamente e normalizadas para obter invariância de escala.

Característica	Descrição	Expressão
f1	Potência total no domínio da frequência	$\log(m_0)$
f2	Estabilizador de ruído	$\log(m_2/m_0^2)$
f3	Estabilizador de ruído	$\log(m_4/m_0^2)$
f4	Energia concentrada em poucos elementos	$\log[m_0 / (\sqrt{(m_0-m_2)}\ \sqrt{(m_0-m_4)})]$
f5	Fator de irregularidade do comprimento de onda	$\log[\sqrt{(m_2^2/(m_0 m_4))}/WL]$

2.5. Formação das imagens

Foram empregados quatro métodos de representação de imagens a partir das características extraídas. “Feature Image”: imagem direta de cada janela, com dimensão 12 × W, em que 12 é o número de canais e W o número de características. “MixChannel Image”: aplica o algoritmo de reorganização [25] aos canais, gerando imagem 72 × W. “MixFeature Image”: reorganiza as características, formando imagem 12 × W, com largura variável por conjunto de características. Não

se aplica a TD-PSD1, que contém apenas duas características já adjacentes. “Mix Image”: reorganiza canais e características, gerando imagem 72 × W, também com largura dependente do conjunto; não se aplica a TD-PSD1, pois seria idêntica à MixChannel Image.

2.6. Arquitetura CNN

A rede utilizada foi a GengNet [7] (Figura 2), composta por oito camadas. As duas primeiras são convolucionais, cada uma com 64 filtros 3 × 3 e max-pooling 2 × 2 após a convolução. As duas seguintes são localmente conectadas, cada uma com 64 filtros 1 × 1. Nas quatro primeiras camadas aplicou-se normalização em lote (Batch Normalization) [35]. Em seguida, há três camadas totalmente conectadas, com 512, 512 e 128 neurônios, e uma camada de saída de 50 neurônios, correspondente às classes. As primeiras sete camadas usam ReLU; a última, softmax.

O treinamento utilizou descida do gradiente estocástico, taxa de aprendizado 0,01, momentum 0,9, batch size 128 e 32 épocas. Os hiperparâmetros foram selecionados por ajuste manual [36]. Conforme [8,10,37], quatro das seis repetições de cada gesto (2/3) foram usadas no treinamento e as duas restantes nos testes. A acurácia de classificação corresponde ao número de classificações corretas dividido pelo número total de amostras de teste, multiplicado por 100%.

$$\text{(12) Acurácia (\%)} = (\text{classificações corretas} / \text{total de amostras de teste}) \times 100$$

3. Resultados

3.1. Base de dados DB2

Na DB2, com janelas de 200 ms e sobreposição de 100 ms, as características TD-PSD2 apresentaram melhor desempenho em todos os casos. O maior desempenho médio entre 40 indivíduos ocorreu com “Mix Image”: 87,56 ± 4,46%. O segundo maior, 87,19 ± 4,53%, foi obtido com TD-PSD2 e “MixChannel Image”, apenas 0,37 ponto percentual inferior. O menor resultado foi 75,08 ± 6,47%, com TD-PSD1 e “Feature Image” (Figura 4).

Com janelas de 150 ms e sobreposição de 25 ms, houve aumento geral de desempenho. O maior resultado ocorreu novamente com TD-PSD2 e “Mix Image”: 97,61 ± 1,55%. O segundo maior foi 97,44 ± 1,11%, com TD2 e “Mix Image”, apenas 0,17 ponto percentual inferior. O menor resultado foi 87,60 ± 5,52%, com TD-PSD1 e “Feature Image”.

Como a diferença entre “Mix Image” e “MixChannel Image” era pequena, os autores compararam os 40 indivíduos diretamente (Figura 5). Para janelas de 200 ms, “Mix Image” melhorou o desempenho de 30 dos 40 indivíduos; para janelas de 150 ms, de 34 dos 40.

3.2. Base de dados DB3

A DB3 apresentou tendência semelhante à DB2 (Figura 6). Com janelas de 200 ms e sobreposição de 100 ms, o maior desempenho foi 74,24 ± 9,45%, com TD-PSD2 e “Mix Image”; o segundo foi 73,55 ± 9,08%, com TD-PSD2 e “MixChannel Image”, uma diferença de 0,69 ponto percentual. O pior resultado foi 60,94 ± 9,44%, com TD-PSD1 e “Feature Image”.

Com janelas de 150 ms e sobreposição de 25 ms, todos os casos melhoraram. TD-PSD2 com “Mix Image” alcançou 90,23 ± 6,82%; com “MixChannel Image”, 90,03 ± 7,57% (diferença de 0,2 ponto percentual). O menor resultado foi 76,77 ± 9,07% para TD-PSD1 e “Feature Image”. Comparando individualmente os 11 participantes (Figura 7), a “Mix Image” melhorou 9 casos com janelas de 200 ms e 7 casos com janelas de 150 ms.

Base	Janela	Características	Imagem	Acurácia (%)
DB2	200 ms	TD-PSD2	Mix Image	87,56 ± 4,46
DB2	150 ms	TD-PSD2	Mix Image	97,61 ± 1,55
DB3	200 ms	TD-PSD2	Mix Image	74,24 ± 9,45
DB3	150 ms	TD-PSD2	Mix Image	90,23 ± 6,82

3.3. Comparação do tempo de processamento

O tempo de processamento foi medido desde a segmentação até a classificação pela CNN, em cinco indivíduos de cada base, por meio do MATLAB R2021a em computador Intel Core i7-6700HQ de 2,60 GHz. O esquema TD-PSD2 com “Mix Image”, referência do estudo por apresentar a maior acurácia, demandou 12 ms para processar uma amostra. Os tempos dependem da quantidade de características e das dimensões das imagens.

TD-PSD1, com apenas duas características, exigiu os menores tempos para “Feature Image” e “MixChannel Image”: 36,44% e 56,07%, respectivamente, do tempo da referência. TD2, com dez características, apresentou os maiores tempos. Com “Mix Image”, consumiu 313,76% mais tempo do que a referência. Todos os tempos ficaram abaixo de 200 ms, atendendo ao limite considerado para interação humano-computador [38].

Na DB2 com janela de 200 ms, o melhor resultado superou o segundo por apenas 0,37 ponto percentual, mas exigiu 23,08% mais tempo de processamento. Com janela de 150 ms, a vantagem de TD-PSD2 sobre TD2 foi de 0,17 ponto percentual, enquanto TD2 exigiu 313,76% mais tempo. Assim, TD-PSD2 pode oferecer uma relação vantajosa entre acurácia e tempo de processamento.

Tipo de imagem	TD1	TD2	TD-PSD1	TD-PSD2
Feature Image	9,0%	15,1%	3,0%	7,5%
MixChannel Image	54,5%	90,9%	18,1%	45,5%
MixFeature Image	27,2%	75,7%	—	16,6%
Mix Image	163,6%	454,5%	—	100%

3.4. Comparação com trabalhos anteriores

A comparação com pesquisas anteriores considera a acurácia, as bases de dados, as classes, o tamanho das janelas, o conjunto de características e os classificadores utilizados. Na DB2 com janelas de 150 ms, 97,61% superou em 8,16 pontos percentuais o resultado de Pancholi et al. [27], de 89,45%. Na DB3, o resultado de 90,23% superou os 81,67% de [27] em 8,56 pontos percentuais. Com janelas de 200 ms, foram relatadas vantagens de 3,86 e 9,94 pontos percentuais sobre os resultados de Wei et al. [26] para DB2 e DB3, respectivamente.

Trabalho	Base	Janela	Acurácia (%)
Atzori et al. [8]	DB2	150 ms	75,27
Atzori et al. [8]	DB3	150 ms	46,27

Trabalho	Base	Janela	Acurácia (%)
Zhai et al. [37]	DB2	200 ms	78,71
Hu et al. [10]	DB2	200 ms	82,20
Wei et al. [26]	DB2	150 ms	82,70
Wei et al. [26]	DB2	200 ms	83,70
Wei et al. [26]	DB3	200 ms	64,30
Pancholi et al. [27]	DB2	150 ms	89,45
Pancholi et al. [27]	DB3	150 ms	81,67
Este trabalho	DB2	150 ms	97,61
Este trabalho	DB2	200 ms	87,56
Este trabalho	DB3	150 ms	90,23
Este trabalho	DB3	200 ms	74,24

4. Discussão

O conjunto TD-PSD2 foi utilizado pela primeira vez para treinar uma CNN voltada ao reconhecimento de gestos com sEMG. Também foi proposto um tipo de imagem que reorganiza canais e características para revelar padrões adjacentes. A classificação da DB3 foi mais difícil, como esperado pela diferença na estrutura muscular de pessoas amputadas em relação a pessoas sem amputação [18].

Desde Atzori et al. [8], com resultados de 75,27% na DB2 e 46,27% na DB3 para janelas de 150 ms, os desempenhos de classificação têm aumentado; CNNs e variantes lideram os resultados. Neste trabalho, TD-PSD2 com “Mix Image” apresentou os melhores desempenhos. Para DB2 com janela de 150 ms, 97,61% foi 8,16 pontos percentuais superior a [27]; com janela de 200 ms, 87,56% superou [26] em 3,86 pontos percentuais. Na DB3, com 150 ms, 90,23% superou [27] em 8,56 pontos percentuais; com 200 ms, 74,24% superou [26] em 9,94 pontos percentuais.

De maneira geral, o domínio do tempo e, particularmente, características relacionadas ao espectro de potência obtidas nesse domínio produziram os melhores resultados. Reorganizar canais e características melhorou o desempenho. Janelas de 150 ms apresentaram resultados superiores; entretanto, o ganho também parece relacionado à menor sobreposição de 25 ms. Não foi possível uma comparação direta de todas as sobreposições, pois nem todos os trabalhos informaram esse parâmetro.

5. Conclusões

Trabalhos recentes de reconhecimento de gestos por sEMG têm obtido bons resultados combinando CNNs com extração de características para formar imagens de treinamento. O tempo de processamento também importa, sobretudo para implementação em próteses eletromecânicas de mão em tempo real. Foram comparados quatro conjuntos de características e quatro representações de imagens, avaliando acurácia e tempo de processamento.

As características obtidas do espectro de potência no domínio do tempo demonstraram os melhores resultados. A reorganização de canais e características elevou o desempenho em menos de 1 ponto percentual em relação à reorganização apenas dos canais, com aumento aproximado de 20% no tempo de processamento.

Em uma implementação em tempo real, é necessário considerar o intervalo disponível para entregar uma nova classificação, relacionado ao deslocamento entre janelas. Pode-se optar por poucas características e imagens menores, favorecendo hardware modesto e eventualmente compensando a perda de desempenho com votação majoritária, ou por características e imagens de melhor desempenho com maior capacidade de processamento. A análise dos tempos apresentada ajuda a escolher o esquema apropriado e o hardware correspondente.

Informações finais

Contribuições dos autores: conceitualização e metodologia — J.A.S.-E., J.A.M.-S. e A.Z.-L.; investigação — J.A.S.-E., J.A.M.-S., A.Z.-L., O.P.-S. e J.G.V.-A.; redação e visualização — J.J.E.-A. e J.A.S.-E.; software — J.G.V.-A., J.A.S.-E. e A.Z.-L.; validação e análise formal — J.A.S.-E., J.A.M.-S., A.Z.-L., O.P.-S. e J.G.V.-A.; recursos — J.A.S.-E. e A.Z.-L.; revisão e edição — todos os autores.

Financiamento: esta pesquisa não recebeu financiamento externo. Declaração de ética: não se aplica. Consentimento informado: não se aplica. Disponibilidade dos dados: projeto NinaPro, http://ninapro.hevs.ch (acesso em 20 de janeiro de 2021). Conflitos de interesse: os autores declaram não haver conflitos de interesse.

As referências numeradas [1–38] remetem à lista bibliográfica do artigo original. Esta versão em português mantém os títulos e a estrutura temática para leitura lado a lado; figuras e gráficos podem ser consultados no PDF original.